

Um paciente, cinco perguntas

William Bendinelli

Instituto de Ciências Matemáticas e de Computação · USP

Resumo

Este relatório explica, para um único paciente, o modelo de óbito por COVID do curso, treinado sobre a base de vigilância SRAG/SIVEP-Gripe. Usa os cinco métodos locais agnósticos de modelo estudados nos módulos 01 a 05: perfis *ceteris paribus*, ICE, LIME, contrafactuais e SHAP. Agnóstico de modelo porque explica por fora, sem abrir a caixa; local porque explica uma predição sobre uma pessoa, e não o modelo inteiro. Em vez de cinco estudos avulsos, o mesmo paciente, escolhido por uma regra, atravessa os cinco, e cada método é julgado por uma pergunta clínica que deveria responder.

Dois achados organizam o texto. O primeiro é que a ficha do SIVEP desliga campos: quando ela declara que não há fator de risco, as comorbidades nem chegam a ser apresentadas a quem preenche. Mexer numa variável de cada vez produz então fichas que o formulário não permitiria, e nesta base essa quantidade não é estimada, é contada. O segundo é que o modelo aprendeu com os anos em que se morria muito mais e prevê num mundo em que se morre menos, e a mesma queda reaparece nos cinco métodos. Todo número em prosa é impresso por uma célula de caderno versionada, e a nota que o acompanha diz onde essa célula vive.

Palavras-chave: interpretabilidade, SRAG/SIVEP-Gripe, *ceteris paribus*, ICE, LIME, contrafactuais, SHAP

1. Introdução

Um método de interpretabilidade **agnóstico de modelo** explica o modelo por fora. Não abre a caixa: não lê coeficientes, não percorre árvores, não olha pesos. Faz o que qualquer usuário faria: muda o que entra e observa o que sai. Por isso serve igualmente para uma regressão logística e para o comitê de árvores deste relatório.

Local é a outra metade do nome. Um método global descreve o modelo inteiro, o que ele faz em média sobre a população toda; um método local explica **uma** predição, sobre **um** paciente. É a diferença entre “o que este modelo faz em geral” e “por que ele disse isto sobre esta pessoa”.

O modelo aqui prevê óbito hospitalar por COVID a partir das variáveis de admissão da ficha de Síndrome Respiratória Aguda Grave (SRAG). No teste de 2024 ele faz AUC 0,7644.¹ Isso se lê assim: tome um paciente que morreu e outro que sobreviveu, e o modelo ordena os dois corretamente nessa fração das vezes. Uma AUC diz o quanto o modelo acerta; não diz em quem, nem por quê. Para um comitê que decide sobre um paciente, essa é a distância entre uma estatística e uma resposta.

Os cinco métodos locais do curso existem para essa pergunta, e aqui todos caem sobre o mesmo modelo, sob uma restrição que muda a leitura: é sempre **o mesmo paciente**. Na ordem em que foram estudados: o perfil *ceteris paribus* (e se a idade fosse outra?), o ICE (os outros pacientes respondem igual?), o LIME (por que esta predição, localmente?), os contrafactuais (o

que teria de mudar?) e o SHAP (quanto cada variável pesou?).

Dois fatos atravessam as cinco seções. O primeiro: a ficha do SIVEP desliga campos. Quando ela registra que não há fator de risco, as treze comorbidades nem chegam a ser apresentadas a quem preenche; não ficam em branco por descuido, não são feitas. Então mexer numa variável de cada vez, deixando as outras paradas, que é o que os cinco métodos fazem, produz fichas que o formulário não permitiria, e nesta base dá para **contar** quantas. Uma regra dessas é uma **cerca**; uma linha que a atravessa é um **paciente impossível**.

O segundo: o mundo mudou no meio. O modelo aprendeu com os anos de 2020 a 2022, quando se morria muito mais, e prevê em 2024, quando a letalidade observada já caíra quase pela metade. Isso é a **deriva de regime**, e ela reaparece nos cinco métodos: na calibração, nas curvas do ICE, no ranking do SHAP. Um achado só, visto por cinco instrumentos.

Vale aqui a regra de evidência do repositório: todo número em prosa é impresso por uma célula de caderno versionada, e as notas de rodapé deste texto dizem onde cada uma vive.

2. O caso: a base, o tratamento e o modelo

A fonte é o SIVEP-Gripe, o sistema com que o Ministério da Saúde vigia a Síndrome Respiratória Aguda Grave: cada internação por SRAG no país vira uma ficha. São 4.109.567 notificações entre 2019 e 2024.²

O tratamento tem três camadas, e a fronteira entre elas é uma pergunta. O **Bronze** é o dado como foi

¹Módulo 00: a AUC do modelo do curso no teste de 2024, lido uma vez só e depois de a escolha estar fechada.

²Módulo 00: a contagem de fichas do extrato congelado que serve a todo o curso; ele é datado porque a ficha muda entre versões.

baixado, byte a byte, nunca alterado: é o que foi publicado? O **Prata** afirma fatos sobre o registro, o tipo de cada campo, os valores que ele admite e os três jeitos diferentes de um campo estar vazio: esse valor está determinado pelo registro sozinho? O **Ouro** faz as escolhas da tarefa, com dono e data: o alvo, a coorte, a janela, a divisão treino/teste e a codificação. Esse valor depende do que se quer prever?

A separação não é estética. Enquanto o alvo não é escolhido, nada no tratamento depende do que se quer prever, e um único Prata serve a todos os módulos do curso. Trocar de alvo não refaz a limpeza.

Aqui o alvo é o óbito entre os casos já fechados, e a coorte é a dos hospitalizados com COVID. Ela sai de um funil de seis filtros, publicado na ordem em que os filtros correm, porque as contagens não comutam: cada "restam tantos" só significa alguma coisa se estiver dito o que saiu antes. Ao fim do funil resta a coorte sobre a qual os cinco métodos trabalham.

A divisão entre treino, validação e teste é temporal, e não sorteada, porque a população não é estacionária: em tempo normal a SRAG é doença de criança, e sob COVID é doença de idoso. Sortear linhas ensinaria ao modelo em que ano o paciente adoeceu. O treino vai até 2022, a validação é 2023 e o teste é 2024.

Na fronteira dessa divisão está o achado que os cinco módulos vão explicar: a letalidade observada cai quase pela metade do treino para o teste. Não é um incômodo a corrigir: é o mundo tendo mudado enquanto os dados eram coletados.

O modelo, escolhido por protocolo

O modelo do curso não foi escolhido por gosto. Antes de qualquer leitura do teste, um protocolo foi escrito e versionado: vence a maior AUC na validação de 2023, e o teste é lido uma vez, depois da escolha, sem poder desfazê-la. Seis famílias concorreram, do modelo constante ao XGBoost, e venceu o XGBoost, com os hiperparâmetros que o próprio estudo ajustou. A regressão logística fica ao lado como termo de comparação, e a distância entre as duas é o problema que este curso existe para resolver.

No teste de 2024 o modelo prevê 0,2154 de risco médio de óbito onde se observa 0,1824.³ Essa diferença entre o que o modelo espera em média e o que de fato aconteceu é o **erro de calibração**: a deriva de regime por dentro do modelo, que aprendeu letalidades antigas e encontrou outro mundo. A capacidade de ordenar pacientes sofre junto, embora menos.

As quatro impossibilidades

Quatro regras da ficha proíbem combinações de valores, e são as quatro cercas desta base. De cada uma se mede a mesma coisa: a fração da amostra que está **em cima** da fronteira, aquela para quem uma única perturbação já cai do lado impossível.

O portão do funil. A ficha desliga as treze comorbidades quando o campo de fator de risco declara que não

há nenhum. Marcar uma comorbidade num paciente nesse estado contradiz um portão que, medido nos seis anos da base, nunca foi contrariado.

A pré-campanha. A campanha de vacinação tem data de início. Quem adoeceu antes dela não pode ter tomado dose nenhuma, e aumentar a contagem de doses inventa uma vacina que ainda não existia.

O critério-2 por um fio. A definição de SRAG exige ao menos um sintoma de cada um de dois grupos: tosse ou dor de garganta; falta de ar, queda de saturação ou desconforto respiratório. Quem entrou marcando **um só** dos dois sintomas do primeiro grupo está por um fio: desligar esse sintoma o tira da definição de caso, e um paciente fora da definição não estaria na base. É o estado mais comum da amostra, de longe.

O critério-3 por um fio. O mesmo, no segundo grupo, com três sintomas em vez de dois e bem menos gente pendurada nele.

Perturbar uma linha através de qualquer dessas fronteiras fabrica um paciente que não pode existir. Os cinco módulos fazem essa conta pela **mesma** função que conta o impossível (`gate_impossible`), o que torna os números idênticos por construção. Quem é esse paciente, e por que uma regra o escolheu, é a próxima seção.

3. O paciente e as três cercas

Quem é o paciente

O paciente deste relatório não foi escolhido a dedo. Ele veio de uma regra escrita antes de olhar: entre todos os pacientes do ano de teste, aquele cuja predição cai mais perto da fronteira da decisão, com o identificador servindo de desempate.

O escolhido, pela regra do módulo 00, é um homem de 90 anos, do Sudeste, que adoeceu na semana 34 de 2024, com uma dose de vacina antes do sintoma e cardiopatia declarada. Ele é o **paciente-regra**, e as cinco perguntas deste relatório são feitas sobre ele.

Estar em cima da fronteira não é acaso conveniente: é a condição que torna as cinco respostas comparáveis. É ali que a reta local do LIME não degenera numa constante e que as forças do SHAP se cancelam de forma legível. Um paciente confortavelmente de um lado só esconderia o que cada método faz quando é obrigado a decidir.

Dois outros aparecem, cada um com uma razão declarada. Os módulos 01 e 03 usam um segundo, escolhido pela mesma regra mas restrito a quem está exposto às três cercas, chamado aqui de **vulnerável**: ele existe para mostrar que a quantidade de ficção que um método fabrica depende de **quem** está sendo explicado. O módulo 04 precisa de um terceiro, com predição bem mais alta, porque contrafactual pede alguém com o que perder.

A legenda vale em todas as figuras deste relatório: **a forma diz de onde o ponto veio; a cor diz o que ele é.**

³Módulo 00: o risco médio que o modelo prevê no teste de 2024, ao lado da letalidade que de fato se observou nesse ano.




Figura 1. A variável-funil: o campo de fator de risco governa se as comorbidades abaixo dele chegam a ser perguntadas. A figura diz quais respostas são possíveis, não quantos pacientes caem em cada ramo.⁴

Círculo é paciente real, colorido pelo desfecho **observado**: azul sobreviveu, terracota morreu. Quadrado é vizinho **sintético**, colorido pela **predição do modelo**. O X escuro é o paciente sendo explicado. No tracejado, escuro e longo é a fronteira do modelo, cinza e médio a vizinhança que um método construiu, claro e curto só andaime de eixo.

A ficha do SIVEP não é um formulário plano: ela **desliga campos**. Quando o campo de fator de risco declara que o paciente não tem nenhum, as treze comorbidades abaixo dele nem chegam a ser apresentadas a quem preenche. O vazio que sobra ali não é dado faltante. É informação: diz que a pergunta não foi feita, e diz por quê.

Por isso o tratamento separa três leituras do vazio: **não se aplica** (o portão desligou o campo), **ausente** (o campo estava aberto e ficou em branco) e **ignorado** (alguém registrou que não sabe). Fundir as três transforma resposta em buraco: o dado faltante cresce sem que nada tenha se perdido, e quem imputa por cima dá comorbidade a quem declarou não ter nenhuma.

Como as features são **conjuntamente restritas**, todo método que perturba uma feature de cada vez fabrica pacientes que não podem existir. Três cercas atravessam os módulos.

cerca	o que ela proíbe
portão do funil	marcar comorbidade em quem declarou não haver fator de risco
calendário da campanha	dar uma dose a quem adoeceu antes de a campanha começar
definição da coorte	apagar o único sintoma que fez o paciente entrar na coorte

Fonte: módulo 00, MODEL.md; a mesma função nos módulos 01 a 05

E a cerca não é vista pela geometria. A distância de Gower compara duas fichas célula a célula, pondo números e categorias na mesma escala; por ela o ponto impossível fica mais perto de um paciente real do que o paciente real mediano fica do vizinho dele. Trocar um nível de categoria custa o mesmo, seja a troca possível

ou impossível: nenhuma checagem por distância pega a contradição.

4. Ceteris paribus: e se a idade fosse outra?

Congela-se o paciente, escolhe-se uma variável e uma **grade** (a lista de valores que ela vai assumir) e plota-se a predição em cada valor. Sem modelo intermediário, sem sorteio, sem aproximação: a curva é a saída do modelo (Molnar, 2025), e é por não aproximar nada que o método mais simples do curso expõe o problema que todos os seguintes herdam.

Um modelo de árvores não lê a idade como um valor que escorre: ele pergunta se a idade passou de um corte, depois se passou do seguinte. Entre dois cortes ele não muda de opinião, então a predição fica parada e pula de uma vez. A curva vira uma **escadaria**.

E a escadaria se lê errado com facilidade. A altura de um degrau é propriedade da grade que você escolheu, não do modelo: pedir a predição em idades mais próximas parte o degrau grande em degraus menores sem que nada mude dentro do modelo. O que não se move é a amplitude, do ponto mais alto ao mais baixo.⁵ Leia posições de corte; nunca alturas de degrau.

A logística desenha a mesma curva para **todo** paciente, mudando só a altura, porque não tem interações. O modelo do curso desenha uma curva por paciente, e é daí que sai o ganho que nenhum coeficiente global exhibe. Nas doses os dois discordam de ponta a ponta, e aí mora uma armadilha: dizer que o modelo do curso "desce nas doses" é ler a ponta do gráfico, não o paciente, porque perto do próprio paciente a inclinação é **positiva**.

A resposta, e o preço. Para a pergunta do título o método responde direto, lendo a curva de idade no valor que interessa. E responde barato: sem sorteio no caminho, repetir a conta devolve a mesma curva. O preço é que a resposta vale para uma linha fabricada, e quanto dela é ficção depende de quem se explica: para o paciente-regra nenhuma das oito variáveis de maior peso fabrica um impossível; para o vulnerável, a mesma

⁴Módulo 00: fundir os três estados infla o dado faltante por 1,8× a 5,7× conforme o ano.

⁵Módulo 01: refinando a grade em quatro passos, a amplitude do perfil de idade fica em 0,4809 e o maior salto cai de 0,1387 para 0,0852.




Figura 2. O mesmo paciente em dois modelos, na idade e nas doses: a escadaria do modelo do curso contra a rampa da logística. Nenhuma das curvas diz o que aconteceria se este paciente tomasse mais uma dose; o perfil prevê, não intervém.⁶

varredura é ficção do começo ao fim. A concentração da ficção é propriedade da coorte, não do método.

5. ICE: os outros respondem igual?

O ICE desenha um perfil *ceteris paribus* por paciente, todos no mesmo eixo (Goldstein et al., 2015). Esse conjunto de curvas é o **feixe**, e o que ele acrescenta é heterogeneidade: o modelo trata todos do mesmo jeito? O teste do capítulo é de olho nu: se todas as curvas seguem o mesmo curso, não há interação, e a média delas, o **PDP**, basta.

Uma curva por paciente significa que, com a base inteira, o gráfico vira uma mancha preta: é o amontoamento (**overcrowding**) de que o capítulo avisa. Por isso se sorteia um subconjunto, e a regra do sorteio se declara.⁷ A **semente** é o número que fixa o sorteio: quem rodar o caderno de novo obtém as mesmas curvas, e é isso que torna a figura reproduzível. **Estratificar por**

ano é tirar a mesma quantidade de pacientes de cada ano; sem estrato, 2020–2022 dominaria a amostra e o regime sumiria no desbalanço.

Está aí a lição do PDP: a média fica entre duas populações e não descreve nenhuma. **Centrar** as curvas confirma: subtraído de cada uma o valor que ela tem no início da grade, todas partem do zero e sobra só a forma, quase paralela, com os pacientes subindo do mesmo jeito de níveis muito diferentes. O PDP acerta a forma e erra o nível de todos ao mesmo tempo, o modo de mentir mais educado que existe.

A **derivada** é a inclinação da curva em cada ponto: quanto a predição muda por um ano a mais. Ela acha o efeito onde ninguém procurava, num pico pediátrico. Não é biologia: é o modelo lendo uma coorte em que a SRAG pediátrica pré-COVID era bronquiolite.

A **resposta, e o preço**. Não, os outros não respondem igual, e a diferença é o ano em que adoeceram. O




Figura 3. Olhe a rampa de intensidade: quanto mais escura a curva, mais letal o regime em que o paciente adoeceu, e as de 2020 correm por cima das de 2024, então o teste do capítulo falha de propósito. A figura não mostra efeito da idade: cada ponto é a predição numa linha fabricada.⁸

⁶Módulo 01, walkthrough §1b: a fig. 12.5 do livro, refeita. Nas doses a logística sobe 0,217 e o modelo do curso termina 0,044 abaixo.

⁷Módulo 02: o feixe sorteia 200 pacientes, 40 por ano, com semente 42.

⁸Módulo 02: 252 dos 1.400 pontos do feixe de doses caem antes de a campanha começar, uma fração derivável antes mesmo de medida.




Figura 4. Os seis passos do método sobre um corte ceteris paribus do modelo do curso: fronteira, vizinhança, perturbação, previsões, pesos e reta. Só o painel D consulta o modelo. A figura não mostra uma vizinhança de pacientes: cada coluna da nuvem é sorteada sozinha.

preço é que a ficção se multiplica por duzentas curvas e continua contável: o feixe de idade não tem um ponto impossível, o de doses fabrica 18% e o de tosse, 54%.⁹ A variável varrida decide se o feixe é retrato ou fábula.

6. LIME: por que esta predição, localmente?

O LIME (Ribeiro et al., 2016) não abre o modelo. Ele fabrica vizinhos artificiais em volta do paciente, pergunta ao modelo o que ele prevê em cada um, dá mais peso aos mais parecidos e ajusta uma reta simples nesse conjunto. Essa reta é o **substituto**: imita o modelo complicado só ali perto, e seus coeficientes são a explicação. O **kernel** decide o peso de cada vizinho conforme a distância, e a largura dele define o tamanho de "ali perto".

O substituto nunca passa por cima do modelo. A predição continua vindo do XGBoost; a reta só a resume.

Três surpresas estão na figura. A nuvem não está centrada no paciente: o gerador padrão a centra na média do treino, e o paciente fica a vários desvios do centro da própria "vizinhança". O kernel descarta quase tudo, e sobram poucos vizinhos com peso apreciável. E é nesse deserto que a reta é ajustada.

A vizinhança tem dois defeitos, e só um tem conserto fácil. Declarar quais colunas são discretas conserta a **gramática**: a nuvem para de produzir códigos que não existem na ficha e doses negativas, e nada avisava, porque a função que entrega os vizinhos ao modelo

arredonda em silêncio. Não conserta a **biologia**: cada coluna continua sorteada sozinha, a correlação entre calendário e doses some, e os vizinhos impossíveis continuam lá, quase um terço dos do paciente-regra e quatro em cada cinco dos do vulnerável.¹⁰

A resposta, e o preço. O LIME dá um ranking com sinal, e o topo dele é firme entre sementes: no módulo 03, dez delas dão o mesmo top-5, sem troca de sinal no top-8. O preço é o R^2 : ele mede o quanto a reta reproduz a nuvem ponderada, não a **fidelidade local**, o quanto a explicação acerta neste paciente. Com kernel estreito o substituto degenera na constante certa e entrega R^2 zero com erro zero, a explicação vazia perfeita; com kernel largo, R^2 e erro sobem juntos.¹¹ Nenhuma largura compra as duas, e a regra é dura: não ranqueie explicações por R^2 . A amostragem fora da variedade abre ainda um ataque: um classificador que detecta as perturbações esconde do LIME o próprio viés.

7. Contrafactuais: o que teria de mudar?

Os três métodos anteriores perguntam "o que pesou?". O contrafactual inverte: qual é a menor mudança que muda a saída? Com isso, as cercas deixam de ser diagnóstico de método doente e viram **restrição de busca**.

Como a saída é um paciente hipotético (Wachter et al., 2018), os critérios de qualidade são sobre pessoas: **validade**, a mudança cruza mesmo o limiar; **proximi-**

⁹Módulo 02, walkthrough §1: aos 80 anos o feixe vale 0,481 em 2020 e 0,303 em 2024, e o PDP reporta 0,400.

¹⁰Módulo 03, walkthrough §4: a contagem de impossíveis reprova 30,6% dos vizinhos sorteados em torno do paciente-regra e 79,2% dos do vulnerável.

¹¹Módulo 03, walkthrough §5: o kernel estreito mede R^2 0,00 com erro 0,00, e o largo, R^2 0,68 com erro 0,028.




Figura 5. Cada barra é uma banda de risco, e a altura é a fração de pacientes dessa banda para quem algum movimento ao alcance de uma pessoa cruza o limiar: olhe o gradiente, que desce conforme o risco sobe. Barra nenhuma não é paciente condenado, nem a figura mede eficácia: é o método sem o que prescrever.¹²

dade, o hipotético fica perto do real; **esparsidade**, mudam poucas coisas; **plausibilidade**, ele poderia existir; **diversidade**, há mais de um caminho.

O módulo não usa biblioteca, e a razão é uma boa lição de engenharia: o espaço de mudanças declarado cabe inteiro na memória, então o caderno enumera todas em vez de otimizar a perda de Wachter. Isso compra cobertura completa, determinismo sem semente e custo de milissegundos. O paciente aqui não é o paciente-regra: o módulo 04 pede alguém com o que perder, e caiu num paciente de 32 anos, com quatro doses, síndrome de Down, doença neurológica, imunodepressão e doença renal.

O gradiente é a leitura difícil da figura: quem mais precisaria de uma saída é exatamente quem não tem nenhuma. E a busca livre explica: a melhor mudança única que ela encontra é apagar do prontuário a saturação baixa, **consequência** da doença e não alavanca; atrás dela vêm voltar a ter 10 anos e recuar o calendário para o começo da pandemia.

Três histórias sem um ingrediente em comum levam o paciente para o lado certo do limiar, e param em previsões bem diferentes: o efeito Rashomon impresso, explicações diferentes e igualmente válidas para o mesmo caso. Qual delas se contaria ao paciente?

A resposta, e o preço. A resposta honesta é **não há**: os dois candidatos ao alcance deste paciente não movem a predição. Um método que só sabe prescrever precisa saber dizer isso. O preço tem duas partes. Válido não é alcançável: os melhores candidatos passam na cerca, mas pedem uma máquina do tempo. E a plausibilidade se decide sobre o candidato inteiro, não sobre

o movimento: recuar o calendário sozinho cai na cerca da campanha, recuá-lo com zero doses não cai.

8. SHAP: quanto cada feature pesou?

O SHAP (Lundberg & Lee, 2017) responde repartindo, e a regra de partilha vem de um teorema sobre jogos (Shapley, 1953). A predição deste paciente é o resultado da partida; o ganho é a diferença entre ela e a predição média, a de quem nada sabe sobre ele; os jogadores são os valores das variáveis. O valor de Shapley reparte esse ganho entre eles de forma que a soma feche. Em árvores, o TreeSHAP (Lundberg et al., 2020) faz a conta de forma exata em vez de aproximá-la, e o modelo do curso já a traz pronta (`pred_contribs`).

Antes da figura, a escala. As contribuições vivem na **margem**: o número que o modelo soma por dentro e que só depois vira probabilidade. É aí que somar as contribuições das 800 árvores do módulo 00 faz sentido; somar probabilidades não faria, porque elas saturam nas pontas.

Que a soma feche é o que separa o SHAP dos outros quatro métodos: aqui não há ajuste que possa sair bom ou ruim, como o R^2 do LIME. As parcelas fecham porque um axioma manda, a eficiência, e a garantia vira verificação, conferida linha a linha no teste inteiro.¹³

O que a figura **não** significa é causa. Um ϕ positivo não diz que aumentar aquela variável aumentaria a predição: diz que, dado o resto do paciente, aquele valor puxou a predição para cima em relação à média. E o modelo dá o caso que quebra: o ϕ das doses de vacina é **positivo** nos vacinados. Não porque vacina mate. O crédito protetor mora na variável colinear, a que declara a vacinação, e o que sobra para a contagem de doses é

¹²Módulo 04, walkthrough §5: dos 624 pacientes de alto risco, 30,3% têm contrafactual acionável, e a fração cai conforme o risco sobe.

¹³Módulo 05, internals §1: as 40 contribuições mais a base reproduzem a margem com desvio máximo $1,05 \times 10^{-5}$ nas 16.142 linhas do teste.




Figura 6. Um cabo de guerra que empata: a idade empurra para cima, a vacinação declarada e o calendário freiam, e o que se olha é a soma, que cai exatamente sobre a margem deste paciente. A figura não é um contrafactual: reparte o que já aconteceu.

marcar os grupos priorizados na campanha. O antídoto está no módulo anterior: subir as doses deste paciente quase não move a predição.

Duas medições fecham o arco. A primeira liga o SHAP à deriva de regime: a variável de calendário está entre as primeiras para mover as predições de 2024 e entre as últimas pelo ganho das divisões (*gain*), a medida de quanto ela ajudou a construir as árvores. Importância para prever não é importância para treinar.

A segunda é o preço do condicionamento. Apagar uma variável para medir o que ela vale tem duas versões: seguir os caminhos que as árvores percorrem de fato, respeitando as correlações aprendidas, ou apagá-la mesmo, montando pacientes que são metade este e metade outro. As direções batem; as magnitudes divergem onde as correlações moram.

A resposta, e o preço. O SHAP responde a última das cinco perguntas com números que somam, e é a única resposta auditável do relatório. O preço é a segunda versão: os pacientes que ela monta são híbridos, e

quase um quarto deles não pode existir, pela mesma função que conta o impossível nos outros módulos.¹⁴ A limitação que o livro-texto enuncia fica contada, em vez de citada.

9. As cercas, lado a lado, e a deriva

Os cinco módulos contaram a mesma coisa com cinco instrumentos, e sempre pela mesma função, escrita uma vez no módulo 00 e importada pelos cinco cadernos. A tabela compara métodos, não implementações.




Figura 7. O painel-armadilha é o da direita: quem não declarou dose recebe crédito negativo; as doses declaradas recebem crédito positivo. Ele não compara vacinado com não vacinado, nem mede efeito de vacina: mostra como o modelo divide crédito entre variáveis que andam juntas.

¹⁴Módulo 05, walkthrough §7: 23,1% das 2.460 linhas híbridas montadas pela variante intervencional são impossíveis.




Figura 8. O que olhar é a cor das barras: a mesma varredura de doses, na mesma grade restrita, sobrevive inteira no paciente pós-campanha e é barrada quase toda no pré-campanha, onde só a dose zero podia ter existido. A figura não mostra efeito de vacina; mostra em quais pontos a pergunta podia ser feita. É assim que o remédio do capítulo funciona, dizendo **quando não perguntar**.

método	o que foi contado	impossível
módulo 01	linhas da amostra barradas pelo portão do funil	37,3%
módulo 01	linhas da amostra que passam no critério por um fio	79,6%
módulo 02	pontos do feixe de doses, onde a cerca é da variável	18%
módulo 03	vizinhos sorteados em torno do paciente-regra	30,6%
módulo 03	os mesmos vizinhos, em torno do vulnerável	79,2%
módulo 04	candidatos a contrafactual, uma célula por vez	3,5%
módulo 05	linhas híbridas montadas pela variante intervencional	23,1%

Fonte: walkthrough §2 (01), §3 (02), §4 (03), §2 (04) e §7 (05)

A tabela não é um ranking de qualidade. A taxa de ficção é propriedade conjunta de três coisas: o método, a variável perturbada e **quem** está sendo explicado. O contrafactual fabrica pouco porque parte de um paciente real e move uma célula por vez. O LIME fabrica muito porque sorteia todas as colunas de uma vez, e fabrica mais que o dobro no vulnerável, pelo mesmo gerador, já que a nuvem nem olha para o paciente.

A deriva, vista por cinco instrumentos

Não são cinco achados, é um só, visto de cinco ângulos. Ele nasce na base: no módulo 00, a letalidade bruta anual cai de 29,0% em 2020 para 8,6% em 2024. O modelo herda a queda como erro de calibração, porque aprendeu num mundo mais letal e prevê morte demais no atual.¹⁵ O ICE dá rosto ao erro, com duas alturas para a mesma idade quando o feixe é estratificado por ano. O SHAP dá um posto: o calendário é das primeiras variáveis por atribuição e das últimas por ganho na construção das árvores. E o contrafactual mostra o lado perverso: os melhores candidatos válidos pedem que o paciente volte ao começo da pandemia.

Uma explicação que revela "ano" está, portanto, **correta**. O modelo aprendeu o regime, e escondê-lo seria pior do que mostrá-lo.

10. Limitações, discussão e o que aprendemos

O que os métodos não dizem

Nenhum dos cinco entrega causalidade. Todos leem um modelo treinado em fichas de vigilância, e uma ficha registra **documentação** tanto quanto biologia. O resultado de imagem demonstra isso: usá-lo melhoraria a AUC, e o sinal viria invertido, com quem tem exame registrado morrendo menos. Não é pulmão, é documentação vazando no rótulo.

A mesma lógica explica a exclusão mais discutida do Ouro. Admissão em UTI e suporte ventilatório são os dois campos clinicamente mais fortes da ficha, e somá-los subiria bastante a AUC.¹⁶ Ficam fora mesmo assim, e o critério não é o tamanho do ganho: é o **instante da predição**. A ficha só os preenche no encerramento da internação, no mesmo ato que digita o desfecho, então usá-los é prever a admissão com informação que ainda não existia. Isso infla o desempenho aparente sem tornar o modelo utilizável (Wolff et al., 2019).

Há ainda o confundimento por capacidade instalada: quem foi ventilado depende de haver leito, e a oferta de leitos era desigual entre as regiões brasileiras. Mover a ventilação num perfil ceteris paribus não mostraria efeito de tratamento, mostraria triagem. Aquele número maior não é um modelo melhor da mesma pergunta; é um modelo de outra pergunta.

O que os dados ensinaram sobre os métodos

A lição principal inverte a direção habitual: em vez de usar o método para entender os dados, foram os dados que qualificaram o método. Numa base cuja estrutura de formulário é conhecida, a advertência de Molnar, de que perturbar variáveis de forma independente cria combinações irreais, vira contagem.

A segunda lição veio de um acidente. Quando o estudo de seleção trocou os hiperparâmetros do modelo do curso, os cinco módulos foram re-sincronizados afirmação por afirmação, e deu para ver **que tipo** de frase sobrevive. Caíram quase só leituras de ponta e narra-

¹⁵Módulo 00, MODEL.md: no teste, o modelo prevê 0,2154 onde se observa 0,1824.

¹⁶Módulo 00, GOLD.md, decisão 3: com os dois campos, a AUC de teste vai de 0,7644 para 0,8514.

tivas bonitas; sobreviveram as contagens de cerca, que não se moveram, porque medem a base e não o modelo. Vale escrever cada frase sabendo de qual das duas se trata.

O que evitar

- **Prosa editada por busca-e-substituição.** Quando o modelo muda, o número muda e a afirmação pode cair junto.
- **Número sem célula que o imprima.** Ou a célula existe, ou o número sai da prosa.
- **Ler a figura em vez da célula.** O gráfico sugere onde a curva vira; a célula diz onde ela vira.
- **PDP lido como "o" efeito.** A média de um feixe não descreve regime nenhum.
- **ϕ positivo lido como causa.** Ele diz o que o modelo creditou àquele valor, não o que aconteceria se o valor mudasse.

O que torna este relatório verificável não é o texto, é a regra: todo número em prosa é impresso por uma célula versionada, a frase que o carrega nomeia o módulo, e um script reprova o arquivo quando isso é quebrado. É barato de manter e caro de fingir. O próximo capítulo é o remédio direto: o ALE condiciona localmente, dentro da vizinhança que a base de fato tem, em vez de atravessar o funil inteiro. E a pergunta que abre o curso e o fecha continua a mesma: **quem são as linhas que você acabou de dar de comer ao modelo?**

Referências

- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation. *Journal of Computational and Graphical Statistics*, 24(1).
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/1705.07874>
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2. <https://doi.org/10.1038/s42256-019-0138-9>
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.º ed.). <https://christophm.github.io/interpretable-ml-book/>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. <https://arxiv.org/abs/1602.04938>
- Shapley, L. S. (1953). A Value for n-Person Games. Em *Contributions to the Theory of Games II: Contributions to the Theory of Games II*. Princeton University Press.
- Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. *Harvard Journal of Law and Technology*, 31(2). <https://arxiv.org/abs/1711.00399>
- Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A Tool to Assess the Risk of Bias and Applicability of Prediction Model Studies. *Annals of Internal Medicine*, 170(1), W1–W33.