

Um paciente, cinco perguntas

William Bendinelli
ICMC-USP · SCC5819

Resumo

Este relatório explica um modelo de óbito por COVID treinado sobre a base SRAG / SIVEP-Gripe (2019–2024) com os cinco métodos locais dos módulos 01–05 do curso: perfis ceteris paribus, ICE, LIME, contrafactuais e SHAP. Em vez de cinco estudos avulsos, um único paciente escolhido por regra atravessa os cinco, e cada método é julgado por uma pergunta clínica que ele deveria responder. Dois fios atravessam o texto. O primeiro é o das **cercas**: a ficha do SIVEP desliga campos condicionalmente, então perturbar features de forma independente fabrica pacientes que não podem existir — e nesta base essa conta é derivável, não estimada. O segundo é a **deriva de regime**: o modelo aprendeu letalidades de 2020–2022 e prevê num mundo de 2024. Todo número citado aqui é impresso por uma célula de caderno versionada, e a sentença que o carrega nomeia o módulo de origem.

Palavras-chave: interpretabilidade, SRAG/SIVEP-Gripe, ceteris paribus, ICE, LIME, contrafactuais, SHAP

1. Introdução

O modelo que este relatório explica prevê óbito hospitalar por COVID a partir de 40 variáveis de admissão da ficha de Síndrome Respiratória Aguda Grave (SRAG). Ele foi escolhido por um protocolo pré-registrado entre seis candidatos e faz AUC 0,7644 no teste de 2024 (módulo 00, `SELECTION.md`). Esse número é tudo o que um relatório de desempenho entrega — e ele não diz **em quem** o modelo acerta, nem **por quê**. Para um comitê que decide sobre um paciente, a diferença entre uma AUC e uma explicação é a diferença entre uma estatística e uma resposta.

Os cinco métodos locais do curso existem para essa pergunta. Cada um a responde de um jeito, e cada um cobra um preço diferente. Este relatório os apresenta na ordem em que foram estudados — ceteris paribus (módulo 01), ICE (módulo 02), LIME (módulo 03), contrafactuais (módulo 04) e SHAP (módulo 05) — mas com uma restrição que muda a leitura: **é sempre o mesmo paciente**. O `gold_id` 1276776 é escolhido por uma regra e não por conveniência, e os cinco métodos são cinco perguntas feitas sobre ele.

Dois fios atravessam as cinco seções.

O primeiro é a tese organizadora do repositório: a ficha do SIVEP **desliga campos condicionalmente**, então as features são conjuntamente restritas, e todo método que perturba, varre ou permuta features de forma independente fabrica pacientes que não podem existir. O `ROADMAP.md` chama isso de “cercas”. A novidade desta base é que a cerca é **derivável** — o portão de comorbidade tem 0,00% de contradição nos seis anos (módulo 00) —, então “isto poderia inflar a conta” vira um número exato, medido pela mesma função em todos os módulos.

O segundo é a deriva de regime. A letalidade observada cai de 31,4% no treino (início até 2022) para 18,2% no teste de 2024 (módulo 00, `gold/MANIFEST.md` §2.4), e o

modelo carrega a lembrança do mundo antigo. A deriva aparece na calibração, aparece nas curvas ICE, aparece no ranking do SHAP — é o mesmo achado, visto por cinco instrumentos.

A regra de evidência do repositório vale aqui sem desconto: **todo número em prosa é impresso por uma célula de caderno versionada**, e a sentença ou legenda que o carrega nomeia o módulo em que a célula vive. O script `tools/check_numbers.py`, rodado sobre este arquivo, é o teste de aceitação dessa regra.

2. O caso: a base, o Ouro e o modelo

A fonte é o SIVEP-Gripe, o sistema de vigilância de SRAG do Ministério da Saúde. São 4.109.567 notificações e 194 colunas entre 2019 e 2024 (módulo 00), num extrato congelado do banco de 26/06/2025, e o tratamento é um medalhão de três camadas cuja fronteira é um teste de pertencimento (módulo 00): o **Bronze** é o download intocado; o **Prata** afirma fatos sobre o registro — tipos, domínios, os três estados do vazio, 226 derivadas com proveniência, num contrato de 194 de 194 colunas com regra e 84 checagens de qualidade (módulo 00) no arcabouço de (Kahn et al., 2016); o **Ouro** faz escolhas de tarefa.

A separação não é estética. Enquanto o alvo não é escolhido, nada no tratamento depende do que se quer prever, e um único Prata serve a todos os módulos do curso. É o Ouro que decide, com dono e data, cinco coisas: o alvo (óbito nos casos fechados), a coorte (hospitalizados com COVID em definição ampla), a janela (a partir de 26/02/2020), o split (temporal) e a codificação (módulo 00, `GOLD.md`). A coorte sai de um funil cujas contagens **não comutam**, e por isso é publicado na ordem em que os filtros correm:




Figura 1: O estudo inteiro numa figura: três anos com um papel cada, a barreira que impede o teste de entrar na escolha, e o placar de validação que elegeu o XGBoost com 0,7564 contra 0,7403 da floresta — a faixa de empate fica vazia, porque nenhum candidato está a menos de um erro-padrão bootstrap (0,0018) do líder (módulo 00, SELECTION.md).

#	Filtro	Restam
0	Prata (sem linhas deslocadas)	4.109.560
1	coorte hospitalizada	2.428.695
2	caso COVID (definição ampla)	1.364.487
3	casos fechados	1.283.801
4	início a partir de 26/02/2020	1.283.745
5	idade presente	1.282.973
6	idade até 120 anos	1.282.970

Fonte: módulo 00, gold/MANIFEST.md §1

O Ouro final tem 1.282.970 internações e 40 features (módulo 00, gold/MANIFEST.md §1 e §2.5). O split é temporal porque a população não é estacionária — treino até 2022, validação em 2023, teste em 2024 — e a assimetria de tamanho é consequência da epidemia, não do desenho:

split	n	óbitos	letalidade
treino (≤ 2022)	1.242.680	390.769	31,4%
validação (2023)	24.148	4.572	18,9%
teste (2024)	16.142	2.945	18,2%

Fonte: módulo 00, gold/MANIFEST.md §2.4

Essa queda pela metade na fronteira do split é o achado que os cinco módulos vão explicar, não um incômodo a corrigir (módulo 00, gold/MANIFEST.md §2.4).

O modelo, escolhido por protocolo

O modelo do curso não foi escolhido por gosto. Um protocolo foi pré-registrado antes de qualquer leitura do teste: o critério primário é a maior AUC na validação

de 2023; modelos dentro de um erro-padrão bootstrap pareado ficam empatados e vão a desempate por calibração, parcimônia e determinância; o teste é lido uma vez, depois da escolha, e não pode mudá-la (módulo 00, SELECTION.md). Seis candidatos — o constante, o modelo linear de probabilidade, a logística, a árvore, a floresta e o XGBoost — foram buscados em 73 configurações declaradas.

O vencedor foi o XGBoost tunado — 800 árvores, profundidade 4, learning_rate 0,05, min_child_weight 100, reg_lambda 5,0, categóricas nativas, semente 42 (módulo 00, MODEL.md). A regra 8 do protocolo foi acionada: como o vencedor divergia dos parâmetros em vigor, o modelo do curso mudou e os cinco módulos de método foram re-sincronizados. A logística fica ao lado como **baseline** interpretável, e a distância entre as duas é o problema que o curso existe para resolver.

modelo	split	AUC	Brier	prev.	obs.
XGBoost	val	0,7564	0,1356	0,2209	0,1893
XGBoost	teste	0,7644	0,1308	0,2154	0,1824
logística	val	0,7206	0,1550	0,2764	0,1893
logística	teste	0,7246	0,1452	0,2419	0,1824

Fonte: módulo 00, MODEL.md

A tabela contém o achado central do relatório em duas colunas. No teste de 2024, o modelo prevê 0,2154 de óbito médio onde se observa 0,1824 (módulo 00, MODEL.md): o **gap de calibração** é a deriva de regime reaparecendo dentro do modelo, que aprendeu letalidades de 2020–2022 e encontrou outro mundo. A discriminação sofre junto, embora menos: por ano de início, a AUC




Figura 2: A variável-funil. Tratar os três estados do vazio como uma coisa só infla a estatística de dado faltante por 1,8× a 5,7× conforme o ano (módulo 00), e imputar por cima inventa pacientes clinicamente impossíveis. É esta estrutura — e não uma preferência estética — que transforma “perturbação independente” num problema contável.

vai de 0,7890 em 2020 a 0,7680 em 2024, com fundo em 0,7451 em 2022 (módulo 00). Na base cheia o modelo faz 0,7680; a amostra commitada de 240.290 linhas que os módulos de método usam custa apenas 0,0036 de AUC (módulo 00).

As quatro impossibilidades

O Ouro carrega o que é preciso para contar ficção. A ficha do módulo 00 desliga as 13 comorbidades quando FATOR_RISC não declara fator de risco, a campanha de vacinação tem data de início, e a coorte tem definição de caso. Cada uma dessas estruturas é uma cerca, e a fração da amostra em **estado vulnerável** a cada uma está medida (módulo 00, MODEL.md):

restrição	fração vulnerável
critério-2 por um fio	79,60%
portão do funil	37,27%
pré-campanha	29,67%
critério-3 por um fio	24,67%

Fonte: módulo 00, MODEL.md

Perturbar uma linha através de uma dessas fronteiras fabrica um paciente que não pode existir. Os cinco módulos fazem essa conta pela **mesma** função (gate_impossible), o que torna os números idênticos por construção e não por disciplina (módulo 00, MODEL.md).

O paciente

O paciente do relatório vem de regra, não de índice: no módulo 00, o menor $|p - 0,5|$ no teste, com desempate por identificador. É o gold_id 1276776, com p(óbito) = 0,500 — 90 anos, masculino, Sudeste, início na semana 34 de 2024, uma dose antes do sintoma, cardiopatia (módulo 00, MODEL.md).

A escolha não é arbitrária: um paciente em cima da fronteira é o único em que a reta local do LIME não degenera, e é aquele em que as forças do SHAP se cancelam de forma legível. Os módulos 01 e 03 usam um segundo paciente pela mesma regra, restrita ao estado vulnerável

às três cercas — o **vulnerável** —, exatamente para mostrar que a quantidade de ficção que um método fabrica depende de **quem** está sendo explicado. O módulo 04 precisa de um terceiro, escolhido por p mais próximo de 0,8: contrafactual pede alguém com o que perder.

3. O paciente e as cercas

Antes das cinco perguntas, uma legenda e uma tese.

A legenda é do curso e vale em todas as figuras deste relatório: **a forma diz de onde o ponto veio; a cor diz o que ele é** (módulo 03, célula “Ferramentas de desenho”). Círculo é paciente real da base, e a cor é o desfecho **observado**: azul sobreviveu, terracota morreu. Quadrado é vizinho **sintético**, e a cor é a **predição do modelo**, na mesma escala — cinza-claro enquanto o modelo ainda não foi consultado. O marcador em X, escuro, é o paciente sendo explicado. E há três trabalhos diferentes para o tracejado, com três traços diferentes: escuro e longo é a fronteira do modelo, cinza e médio é o anel do kernel (um construto nosso, não do modelo), claro e curto é andaime de eixo. Já aconteceu de uma sala ler uma janela de eixo como se fosse uma vizinhança.

A tese é o que dá unidade ao relatório. A ficha do SIVEP não é um formulário plano: ela **desliga campos condicionalmente**. Quando FATOR_RISC diz que não há fator de risco (módulo 00), as 13 comorbidades nem são apresentadas ao digitador — e o vazio resultante não é dado faltante, é informação. O portão foi medido nos seis anos com 0,00% de contradição (módulo 00), e é por isso que o Prata separa três leituras do vazio (nao_aplicavel, ausente, ignorado) em vez de fundi-las.

A consequência é a frase que organiza o curso: como as features são **conjuntamente restritas**, todo método que perturba, varre ou permuta features de forma independente — ceteris paribus, ICE, LIME, Shapley marginal, PDP, importância por permutação — fabrica pacientes que não podem existir (ROADMAP.md, “A tese organiza”).

A escadaria varre mais que a rampa na idade — e discorda dela nas doses




Figura 3: O mesmo perfil em dois modelos — a fig. 12.5 do livro, refeita no módulo 01. Neste paciente a escadaria varre **mais** que a rampa na idade (0,481 contra 0,397), e nas doses os dois discordam ponta a ponta: a logística sobe +0,217, monótona, carregando o confundimento de quem-se-vacinou, e o XGBoost termina 0,044 abaixo de onde começou (módulo 01, walkthrough §1b).

Três cercas concretas aparecem em todos os módulos:

cerca	o que ela proíbe
portão do funil	marcar uma comorbidade num registro que declarou não haver fator de risco
calendário da campanha	uma dose de vacina antes de a campanha existir
definição da coorte	um sintoma-fio removido de quem só entrou na coorte por ele

Fonte: módulo 00, MODEL.md; a mesma função nos módulos 01 a 05

Duas propriedades tornam essa contagem incomum. Primeiro, ela é **derivável**: não é um envelope empírico com piso geométrico, é a regra do formulário lida no dado. Segundo, ela **não é vista pela geometria**: no módulo 01, o ponto impossível fica a distância de Gower 0,0037 de um paciente real — mais perto que o ponto possível (0,1287) e mais perto do que o paciente real mediano fica do vizinho dele (0,0046). Uma checagem genérica de plausibilidade por distância não pegaria a contradição: mudar um nível de categoria custa o mesmo, seja ele impossível ou não.

4. Ceteris paribus: e se a idade fosse outra?

PERGUNTA 1

Se este paciente não tivesse os 90 anos que tem (módulo 00), o que o modelo preveria?

O perfil ceteris paribus é o método mais simples do curso. Congela-se o paciente, move-se uma variável ao longo de uma grade e plota-se a predição. Não há substituto, kernel nem amostragem: a curva **é** a saída do modelo, avaliada em linhas que se constroem copiando o paciente e trocando uma célula (Molnar, 2025). É por não aproximar nada que ele é o lugar certo para expor o problema que todos os métodos seguintes herdam.

O que o livro diz — Molnar, cap. 12

O capítulo apresenta o método como “one of the simplest analysis one can do”, e avisa que manipular uma feature com as outras paradas cria combinações irreais — a limitação que este módulo transforma em contagem (módulo 01, README).

O mecanismo tem uma consequência que se lê errado com facilidade. O perfil de um modelo de árvores é uma **escadaria**, e a altura de um degrau é propriedade da grade, não do modelo: refinar do passo 10 ao passo 1 deixa a amplitude intacta em 0,4809 nos quatro passos, enquanto o maior salto aparente desmonta de 0,1387 para 0,0852 e então não cede mais (módulo 01, internals §1). Leia posições de corte; nunca alturas de degrau.

Há três coisas para olhar na figura. A primeira é a forma: a logística desenha a mesma curva para **todo** paciente, mudando só o nível, porque não tem interações — e os quatro pontos de AUC que o XGBoost ganha são feitos exatamente daquilo que nenhum coeficiente global exhibe. A segunda é a amplitude, e ela contraria a intuição de que a reta é mais agressiva. A terceira é o painel de doses, e é a mais importante: dizer “o XGBoost desce nas doses” é ler a ponta, não o paciente. O perfil não é monótono — sobe até a segunda dose — e a inclinação local na vizinhança do próprio paciente é **positiva**, +0,03542 (módulo 01, internals §4). O que a figura **não** mostra é efeito de intervenção: nada aqui diz o que aconteceria se este paciente tomasse mais uma dose.

A resposta, e o preço. Para a pergunta 1 o método responde diretamente, lendo a curva de idade no ponto desejado. E responde barato: sem semente, sem aproximação — com subamostragem desligada o XGBoost é determinístico, e no módulo 01 doze sementes dão correlação 1,0000 entre perfis (internals §2). O preço é que a resposta vale para uma linha que o método fabricou. Para este paciente, as oito features de maior ganho dão 0% de varredura impossível (módulo 01, walkthrough §painel) — ele é imune a duas cercas. Para o vulnerável, a mesma varredura é ficção integral: 1 de 1 em diabetes, 6 de 6 em doses. Na amostra, 37,3% dos pacientes estão atrás do portão, 29,7% são pré-campanha e 79,6% têm o critério por um fio (módulo 01, walkthrough §2). A concentração da ficção é propriedade da coorte, não do método — e um paciente só esconderia o achado.

5. ICE: os outros respondem igual?

PERGUNTA 2

Aos 80 anos o feixe vale 0,481 em 2020 e 0,303 em 2024 — o PDP diz 0,400




Figura 4: O teste do capítulo falha de propósito: as curvas **não** seguem o mesmo curso. Aos 80 anos o feixe vale 0,481 para quem adoeceu em 2020 e 0,303 para quem adoeceu em 2024, e o PDP reporta 0,400 — um número que não descreve regime nenhum (módulo 02, walkthrough §1).

A curva de idade dos seus 90 anos (módulo 00) vale para os outros, ou ele é um caso à parte?

O ICE responde desenhando o feixe — um perfil *ceteris paribus* por paciente, todos no mesmo eixo (Goldstein et al., 2015). O ganho sobre o módulo 01 é heterogeneidade — e o teste que o capítulo propõe é de olho nu: se todas as curvas seguem o mesmo curso, não há interação e a média (o PDP) basta. A regra de amostragem precisa ser declarada, porque o próprio capítulo avisa do **overcrowding**; aqui são 200 pacientes, 40 por ano, semente 42 (módulo 02, walkthrough §1). Estratificar por ano é o que deixa o regime visível: sortear sem estrato o afogaria no desbalanço, já que 2020–2022 domina a base.

O que o livro diz — Molnar, cap. 13

O capítulo promete que “ICE curves can uncover heterogeneous relationships”. Nesta base a heterogeneidade tem nome próprio — regime — e as três variantes do capítulo (feixe com PDP, centrado, derivada) viram as quatro seções do caderno (módulo 02, walkthrough).

O que olhar é a rampa de intensidade: quanto mais escura a curva, mais letal o regime em que o paciente adoeceu. As curvas de 2020 correm por cima, as de 2024 por baixo, e a separação é grande o bastante para que a média fique entre duas populações em vez de descrever qualquer uma. O que a figura mede é a predição do modelo em cada idade da grade, para os 200 pacientes reais do módulo 02. O que ela **não** mede é efeito da idade: um feixe é uma coleção de perguntas contrafactuais mal-postas, e a advertência causal do cap. 12 vale dobrada aqui.

Duas leituras completam o quadro. Centradas na idade zero, as curvas mostram só a **forma**, e ela é quase paralela: o ganho de 0 a 100 anos vai de 0,247 no percentil 10 a 0,623 no percentil 90, com correlação mediana de 0,983 com a média (módulo 02, walkthrough §2). Para idade, portanto, o PDP acerta a forma e erra o nível de todos ao mesmo tempo — o modo de mentir mais educado que existe. E a derivada acha o efeito onde ninguém procurava: o pico é **pediátrico**, 0,0239 por ano aos 10

anos, contra mediana de 0,00326 no miolo de 40 a 54 anos (módulo 02, walkthrough §4). Não é biologia: é o modelo lendo uma coorte em que a SRAG pediátrica pré-COVID era bronquiolite.

A resposta, e o preço. Não, os outros não respondem igual — e a diferença é o ano em que adoeceram. O preço é que a ficção se multiplica por 200 e continua contável. No módulo 02, o feixe de idade é logicamente seguro (0 de 10.200 pontos impossíveis); o de doses fabrica 252 de 1.400, 18% — exatamente os 42 pacientes pré-campanha vezes as 6 doses varridas, conta **derivável antes de medida** (módulo 02) —; e o de tosse chega a 54% (walkthrough §3 e internals §3 do módulo 02). A escolha da feature varrida decide se o feixe é retrato ou fábula. Vale registrar que essas contagens não se moveram um ponto quando o modelo do curso mudou (módulo 02): a cerca é da base, não do modelo.

6. LIME: por que esta predição, localmente?

PERGUNTA 3

Que features sustentam esta predição na vizinhança deste paciente?

O LIME (Ribeiro et al., 2016) troca a varredura por um substituto. Ele perturba o paciente, pergunta ao modelo o que prevê em cada vizinho, pesa os vizinhos por proximidade e ajusta uma reta regularizada nesse conjunto ponderado. O objetivo tem três termos — a perda ponderada pelo kernel, a família de modelos simples e a penalidade de complexidade — e o mais importante a dizer em voz alta é que o substituto **nunca passa por cima** do modelo: a predição continua vindo do XGBoost, a reta só a resume (módulo 03, walkthrough §objetivo). A análise teórica de (Garreau & von Luxburg, 2020) registra que falta uma heurística fundamentada para a largura do kernel — o problema aberto que a medição da seção ilustra.

o método inteiro, num paciente


Local Interpretable Model-agnostic Explanation — paciente-regra, $p(\text{óbito}) = 0,500$, $R^2 \text{ local} = 0,40$ (plano idade $\times$ meses; as outras 38 congeladas no paciente)

Figura 5: Os seis passos do LIME sobre um corte ceteris paribus do XGBoost real. Três surpresas já estão aqui: a nuvem não é centrada no paciente — ele está a 6,7 desvios do centro dela —, o kernel descarta quase tudo (0,1% dos vizinhos com peso acima de 0,1) e a reta final é ajustada nesse deserto, com R^2 0,399 (módulo 03, walkthrough §0).

O que o livro diz — Molnar, cap. 14

O capítulo define a meta do substituto e nomeia a medida: “*This kind of accuracy is also called local fidelity*”. O módulo mede o que essa fidelidade é neste caso — e conclui que fidelidade local não é fidelidade ao local (módulo 03, walkthrough §5).

Os painéis A e B mostram a fronteira do modelo no corte e o anel de meia-altura do kernel, que no módulo 03 mede ± 16 anos por $\pm 5,7$ meses: “local” tem esse tamanho. O painel C é o que costuma surpreender — a nuvem não está sobre o paciente, porque o gerador default centra a gaussiana na média do treino, e isso está lido no fonte instalado, não suposto (módulo 03, internals §1). O painel D é o único momento em que o modelo é consultado; o E mostra o peso; o F, a reta. O que a figura não mostra é uma vizinhança de pacientes: mostra um sorteio marginal por feature.

E é essa a contagem que o módulo faz. Na rodada ingênua do módulo 03, sem declarar categóricas, 4.999 de 5.000 vizinhos carregam pelo menos um código fabricado, a idade sintética vai a 126,9 anos e 34,3% têm doses negativas — e nada avisa, porque o **wrapper** de predição arredonda em silêncio (módulo 03, walkthrough §2). Declarar as 36 discretas zera os códigos fabricados e sobe o R^2 a 0,65 baixando o erro no próprio paciente a 0,008 (módulo 03, walkthrough §3). Mas isso conserta a **gramática**, não a **biologia**: cada coluna continua sorteadada sozinha, a correlação entre calendário e doses é +0,61 no treino real e -0,004 na nuvem, e 30,6% dos vizinhos do paciente-regra — 79,2% dos do vulnerável — continuam impossíveis (módulo 03, walkthrough §4 e internals §2).

A resposta, e o preço. O LIME dá um ranking com sinal, e o topo dele é firme: dez sementes produzem o mesmo top-5 (Jaccard 1,00) e nenhuma troca de sinal no top-8 (módulo 03, walkthrough §6). A areia está uma posição

adiante — 3 das 8 features do topo somem do top-10 em alguma semente, e com nuvens menores o mínimo volta a 0,43 (módulo 03, internals §5). O preço maior, porém, é o R^2 : com kernel estreito o modelo local degenera na constante certa e entrega R^2 0,00 **com erro 0,00** — a explicação vazia perfeita —; com kernel largo, R^2 0,68 e erro 0,028 no paciente. As duas curvas sobem juntas, não há largura que compre as duas, e a regra prática é dura: **não ranqueie explicações por R^2** (módulo 03, walkthrough §5). A amostragem fora da variedade, que a contagem de cercas mede, é também a porta do ataque de (Slack et al., 2020): um classificador que detecta as perturbações esconde seu viés do LIME. O survey de (Knab et al., 2025) mapeia as variantes propostas para cada um desses estágios — e a regra prática do repositório é rodar nelas as mesmas medições antes de adotar qualquer uma.

7. Contrafactuais: o que teria de mudar?

PERGUNTA 4

Qual é a menor mudança que muda a predição — e ela está ao alcance de alguém?

Os três métodos anteriores perguntam “o que pesou?”. O contrafactual inverte: qual é a menor mudança que muda a saída? A inversão muda também o papel das cercas, que deixam de ser diagnóstico de método doente e viram **restrição de busca**. Este é o único método do curso cuja saída é um paciente hipotético (Wachter et al., 2018), e por isso o único em que os critérios de qualidade são sobre pessoas: validade, proximidade, sparsidade, plausibilidade e diversidade (módulo 04, walkthrough §1).

O módulo não usa biblioteca. O espaço declarado deste problema cabe inteiro na memória — 113 mudanças simples e 6.129 pares —, então a perda de Wachter é **enumerada** em vez de otimizada, o que dá cobertura

§5 - ALAVANCAS

A saída acionável desaparece exatamente onde o risco é maior




Figura 6: No módulo 04, dos 624 pacientes de alto risco no teste, 30,3% têm contrafactual acionável e 69,7% não têm — e a fração cai conforme o risco sobe: 35% na banda 0,5–0,6 e 0% acima de 0,7, onde nenhum dos 19 pacientes tem saída (módulo 04, walkthrough §5).

completa, determinismo e custo de milissegundos (módulo 04, walkthrough §2). O NSGA-II multiobjetivo de (Dandl et al., 2020) seria o caminho se o espaço não coubesse, e a diversidade otimizada de (Mothilal et al., 2020) fica citada e não executada, por decisão registrada no PR do pin. O paciente aqui é outro, escolhido por p mais próximo de 0,8 (módulo 04): 32 anos, quatro doses, síndrome de Down, doença neurológica, imunodepressão e doença renal.

O que o livro diz — Molnar, cap. 15

O capítulo elogia a limpeza do método: “*There are no additional assumptions and no magic in the background*”. O módulo mede o preço dessa limpeza — sem uma lista de alavancas, a menor mudança devolve “apague do prontuário a saturação baixa” (módulo 04, walkthrough §2).

Cada barra é uma banda de risco previsto; a altura é a fração de pacientes daquela banda para quem existe alguma combinação de movimentos **ao alcance de uma pessoa** — subir doses, declarar o que há a declarar — que cruze o limiar. O que o painel mede é cobertura de prescrição, não eficácia clínica. E o que ele **não** significa é que os pacientes sem barra estejam condenados: significa que, dentro do espaço de alavancas declarado e no limiar escolhido, o método não tem nada a prescrever. A objeção do limiar está medida: em 0,5 a cobertura é 30,3%, em 0,4 cai a 9,3% e em 0,3 a 1,1% (módulo 04, internals §4). O limiar é decisão de quem opera; a conta acompanha.

O gradiente é a leitura difícil da figura: quem mais precisaria de uma saída é exatamente quem não tem nenhuma. E a busca livre explica por quê. A melhor mudança única do mundo é apagar do prontuário a saturação baixa, que derruba a predição de 0,793 para 0,571 e é **consequência** da doença, não alavanca; logo atrás vêm voltar a ter 10 anos e recuar o calendário para o mês 6 da pandemia (módulo 04, walkthrough §2). Dos 68 candidatos válidos, três histórias com features **disjuntas** levam a predições diferentes — 0,199, 0,316 e 0,452 — sem um ingrediente em comum: é o efeito Rashomon im-

presso, e a pergunta que ele deixa é qual dessas receitas se contaria ao paciente (módulo 04, walkthrough §4).

A resposta, e o preço. Para este paciente a resposta honesta é **não há**: os dois candidatos acionáveis que ele tem deixam a predição em 0,793, onde ela já estava (módulo 04, walkthrough §5). Um método de explicação que só sabe prescrever precisa saber dizer isso. O preço tem duas partes. A primeira é que **válido** não é **alcançável**: os melhores candidatos “existem” — passam na cerca —, mas pedem uma máquina do tempo. A segunda é que a plausibilidade se decide sobre o candidato inteiro, não sobre o movimento: recuar o calendário sozinho cai na cerca pré-campanha, e recuá-lo **com zero doses** não cai (módulo 04, walkthrough §3). Em compensação, este é o método que menos fabrica ficção: só 3,5% dos 113 movimentos caem na cerca, contra 30,6% dos vizinhos do LIME pela mesma régua (módulo 04, walkthrough §2). Quem parte de um paciente real inventa pouco.

8. SHAP: quanto cada feature pesou?

PERGUNTA 5

Quanto exatamente cada valor de feature contribuiu para esta predição?

O SHAP (Lundberg & Lee, 2017) é o único método do curso com uma garantia de **soma**. O jogo é a predição desta instância, o ganho é a diferença para a predição média, os jogadores são os valores das features, e o valor de Shapley (Shapley, 1953) reparte esse ganho pelos jogadores. Em árvores, o TreeSHAP (Lundberg et al., 2020) calcula essa repartição de forma exata — aqui pelo `pred_contribs` que já mora no XGBoost — e a propriedade da eficiência deixa de ser promessa e vira verificação: as 40 contribuições do módulo 00 mais a base reproduzem a margem com desvio máximo $1,05 \times 10^{-5}$ nas 16.142 linhas do teste, e três refits dão contribuições bit-idênticas (módulo 05, internals §1).

§1 · WATERFALL

Idade +0,92 contra vacinação -0,36: as 40 parcelas somam $f(x)$ exatamente




Figura 7: O cabo de guerra que empata (módulo 05): partindo da base $-0,79$ em margem (sigmoide 0,31, a prevalência do treino), a idade empurra $+0,92$, a vacinação declarada freia $-0,36$, o calendário freia $-0,32$ e a zona desconhecida empurra $+0,16$ — e a soma dá exatamente a margem do paciente (módulo 05, walkthrough §1).

O que o livro diz — Molnar, cap. 17

A força do método é a eficiência: a diferença entre a predição e a predição média é “fairly distributed among the feature values of the instance”. O cap. 18, por sua vez, registra que o condicionamento por caminho “can produce unintuitive attributions” — as duas afirmações são medidas no módulo 05.

O que olhar é a soma, não o tamanho das barras: elas fecham porque um axioma manda, não porque um ajuste foi bom. O que a figura mede é a contribuição de cada valor **em relação à predição média**, na escala de margem — o espaço em que somar as 800 árvores do módulo 00 faz sentido. O que ela **não** significa é causa, nem contrafactual: um ϕ positivo não diz que aumentar a feature aumentaria a predição. O painel de dependência mede essa armadilha em carne viva: o ϕ das doses é **positivo** nos vacinados, $+0,08$ em três ou mais doses (módulo 05, walkthrough §5). Não porque vacina mate, mas porque o crédito protetor mora na declaração colinear e o que sobra para a contagem de doses é marcar os grupos priorizados — e o antídoto foi medido no módulo 04, onde subir doses quase não move a predição.

Duas medições fecham o arco. A primeira liga o SHAP à deriva: meses é a 3ª feature por média de $|SHAP|$ e a 19ª por **gain** (módulo 05, walkthrough §4). Importância para prever 2024 não é importância para construir árvores em 2020–2022 — é a deriva do módulo 02 vista pela atribuição. A segunda é o preço do condicionamento alternativo. O $pred_contribs$ é **path-dependent**; o pacote de referência mudou seu default para o **interventional**, e medi-lo à mão pelo estimador de permutações de (Štrumbelj & Kononenko, 2014) mostra direções iguais mas magnitudes diferentes onde as correlações moram — a idade vai de $+0,92$ a $+1,03$ e a vacinação de $-0,36$ a $-0,51$ (módulo 05, walkthrough §6).

A resposta, e o preço. O SHAP responde a pergunta 5 com números que somam, e é a única resposta auditável do relatório. O preço aparece exatamente onde o LIME já havia pagado: o estimador **interventional** compra sua leitura avaliando o modelo em híbridos, e 23,1% das

2.460 linhas híbridas são pacientes impossíveis pela mesma `gate_impossible` — portão 15,4%, dose pré-campanha 8,2% (módulo 05, walkthrough §7). A limitação que o cap. 18 enuncia como “ignora a dependência entre features” fica, aqui, contada em vez de citada.

9. As cercas, lado a lado, e a deriva

Os cinco módulos mediram a mesma coisa com cinco instrumentos. Como a contagem sai da mesma função (`gate_impossible`, módulo 00), as frações são comparáveis — e a comparação é o resultado mais forte deste relatório.

método	o que foi contado	impossível
módulo 01	amostra atrás do portão do funil	37,3%
módulo 01	amostra com o critério por um fio	79,6%
módulo 02	pontos do feixe de doses (252 de 1.400)	18%
módulo 03	vizinhos do paciente-regra	30,6%
módulo 03	vizinhos do vulnerável	79,2%
módulo 04	movimentos simples enumerados	3,5%
módulo 05	linhas híbridas do interventional	23,1%

Fonte: walkthrough §2 (01), §3 (02), §4 (03), §2 (04) e §7 (05)

A tabela não é um ranking de qualidade. Ela mostra que a taxa de ficção é uma propriedade conjunta de três coisas: o método, a feature perturbada e **quem** está sendo explicado. O contrafactual fabrica pouco porque parte de um paciente real e move uma célula por vez. O LIME fabrica muito porque sorteia todas as colunas de uma vez, e fabrica **mais que o dobro** no vulnerável — pelo mesmo gerador, já que a nuvem não olha para o paciente (módulo 03, walkthrough §4). O ICE de idade não fabrica nada e o de doses fabrica 18% porque a cerca é da feature, não do feixe (módulo 02). E o SHAP paga 23,1% apenas na variante **interventional**: o exato de caminho não avalia híbrido nenhum (módulo 05).

Uma nota sobre comparar números entre módulos: 79,6% no módulo 01 e 3,6% na variante local do módulo 03 não se contradizem. São perguntas diferentes — flip

A grade restrita preserva a curva de um paciente e remove a pergunta do outro




Figura 8: O remédio do próprio capítulo, medido no módulo 01. Para um paciente pós-campanha a grade restrita preserva a curva inteira (amplitude 0,0896 antes e depois, nenhum ponto impossível); para um pré-campanha, ela **remove** — no módulo 01, 0,0119 vira 0,0000, com 6 de 7 pontos barrados (walkthrough §4). Restringir a grade funciona dizendo **quando não perguntar**.

forçado de um sintoma contra sorteio pela prevalência — medidas pela mesma régua (módulo 03, walkthrough §4).

A deriva, vista por cinco instrumentos

O segundo fio é o mesmo achado aparecendo em cinco lugares. Ele nasce na base: a letalidade bruta anual vai de 29,0% em 2020 a 8,6% em 2024, e a fração de casos COVID de 70,2% a 11,6% (módulo 00). Entre os splits, a letalidade observada cai de 31,4% para 18,2% (módulo 00).

O modelo herda a queda como **erro de calibração**: prevê 0,2154 onde se observa 0,1824 no teste (módulo 00, MODEL.md), e a AUC por ano de início desce de 0,7890 a 0,7680 (módulo 00). O ICE dá rosto ao número: o feixe de idade estratifica por ano, e aos 80 anos vale 0,481 para 2020 contra 0,303 para 2024 (módulo 02, walkthrough §1). O SHAP dá um posto: a feature de calendário é a 3ª por atribuição média e a 19ª por **gain** (módulo 05, walkthrough §4). E o contrafactual mostra a deriva do lado perverso — os melhores candidatos válidos do módulo 04 pedem literalmente que o paciente volte ao mês 6 da pandemia (módulo 04, walkthrough §3).

A conclusão a carregar é que uma explicação que revela “ano” está **correta**. O modelo aprendeu o regime, e negar isso seria pior do que mostrá-lo.

10. Limitações, discussão e o que aprendemos

O que os métodos não dizem aqui

Nenhum dos cinco entrega causalidade. Todos leem um modelo treinado em fichas de vigilância, e o modelo lê **documentação** tanto quanto biologia. A demonstração mais limpa disso está no módulo 00: com o resultado de imagem como feature, a AUC de teste subiria de 0,7644 para 0,7682, e o sinal seria **invertido** — a letalidade é 30,5% sem registro de imagem contra 28,5% com registro (módulo 00). É qualidade de documentação vazando no rótulo, não pulmão.

A mesma lógica explica a exclusão mais discutida do Ouro. UTI e SUPPORT_VEN são os dois campos clinicamente

mais fortes da ficha, e somá-los levaria a AUC de teste de 0,7644 a 0,8514, com Δ de 0,087 no bootstrap pareado (módulo 00, GOLD.md, decisão 3). Ficam fora mesmo assim, e o critério não é o tamanho do ganho: é o **instante da predição**. A ficha só os preenche no encerramento — SUPPORT_VEN não tem data nenhuma, e a data de entrada em UTI existe numa minoria dos registros —, o que os põe do lado errado da questão 2.3 do PROBAST (Wolff et al., 2019) e do item 9b do TRIPOD+AI (Collins et al., 2024); (Wynants et al., 2020) atribuíram a essa causa parte do alto risco de viés dos modelos de COVID revisados. Há ainda confundimento por capacidade instalada: (Ranzani et al., 2021) contaram 36.046 óbitos entre 45.205 ventilados mecanicamente nas primeiras 250 mil interações brasileiras por COVID, com oferta de leitos de UTI muito desigual entre regiões — mover support_ven num perfil ceteris paribus não mostraria efeito de tratamento, mostraria triagem. Trabalhos que fazem a pergunta da admissão sem essas colunas ficam na mesma faixa do nosso modelo: 0,767 no 4C (Knight et al., 2020), 0,813 em (Baqui et al., 2021) sobre o mesmo banco, e o ABC2-SPH (Marcolino et al., 2021) as exclui por desenho. Os 0,8514 do módulo 00 não são um modelo melhor da mesma pergunta; são um modelo de outra pergunta (van Geloven et al., 2020).

O que os dados ensinaram sobre os métodos

A lição principal é a das cercas, e ela inverte a direção habitual: em vez de usar o método para entender os dados, foram os dados que qualificaram o método. Numa base cuja estrutura de formulário é conhecida, a limitação que Molnar enuncia em prosa — perturbação independente cria combinações irreais — deixa de ser advertência e vira número. E o número tem endereço: 30,6% no LIME (módulo 03), 18% no feixe de doses do ICE (módulo 02), 23,1% nos híbridos do SHAP (módulo 05) e 3,5% no contrafactual (módulo 04).

A segunda lição veio de um acidente instrutivo. O estudo de seleção do módulo 00 trocou os hiperparâmetros do modelo do curso, e os cinco módulos foram re-sincronizados número a número. A regra 3 da barra de evidência foi aplicada em dois níveis: uma nota coletiva de condi-

cionamento por módulo e um registro individual “dizia X, mede Y” para cada afirmação que a medição derrubou. Caíram quatro afirmações no módulo 01, nenhuma no módulo 02, quatro no módulo 03, oito no módulo 04 e uma no módulo 05 (CHANGELOG.md, 2026-09-02).

O que essa contagem revela é mais interessante que ela mesma. As afirmações que caíram foram, quase todas, **leituras de ponta** ou **narrativas bonitas**: “a amplitude converge com a grade”, “a rampa é mais agressiva que a escadaria”, “o XGBoost desce nas doses”, “a melhor mudança é rejuvenescer 71 anos”. As que sobreviveram foram as contagens de cerca — que não se moveram um ponto sob o novo modelo (módulo 02), porque medem a base e não o modelo. Um erro de Gower do módulo 01 nem sequer era do modelo novo: a prosa citava 0,043 onde a célula sempre imprimira 0,0491, e a discrepância só apareceu quando alguém conferiu token a token.

Vale registrar também o que o painel das oito features de maior ganho imprimiu para o paciente-regra: 0% de varredura impossível (módulo 01). Um resultado nulo, publicado — e ele é a metade que faltava do achado, porque é a prova de que a ficção depende de quem se explica.

O que evitar

- **Prosa editada por busca-e-substituição.** Quando o modelo muda, o número muda e a afirmação pode cair. Trocar dígitos sem reler a frase produz texto que passa a bater com o caderno e continua mentindo.
- **Número sem célula que o imprima.** É a regra dura do repositório: ou a célula existe, ou o número sai da prosa.
- **Ler a figura em vez da célula.** Uma afirmação do módulo 05 dizia “acima de 70 anos” porque foi lida no gráfico; virou a janela impressa de 78 a 90 anos.
- **PDP como “o” efeito.** Aos 80 anos ele reporta 0,400 e não descreve regime nenhum (módulo 02).
- **LIME sem declarar categóricas.** Sem isso, 4.999 de 5.000 vizinhos carregam código fabricado e nada avisa (módulo 03).
- **Contrafactual plausível mas inalcançável.** Passar na cerca responde “isso existe?”, nunca “dá para chegar lá daqui?” (módulo 04).
- **ϕ positivo lido como causa.** O ϕ das doses é positivo nos vacinados (módulo 05); a leitura causal está medida como errada no módulo 04.

A barra de evidência como método

O que torna este relatório verificável não é o texto: é a regra. Todo número em prosa é impresso por uma célula versionada; a sentença que o carrega nomeia o módulo; correções ficam no registro em vez de sumirem — e há um script que reprova o texto quando a regra é quebrada. É barato de manter e caro de fingir.

O que vem a seguir

O ROADMAP.md já nomeia os próximos passos como capítulos-remédio e capítulos-armadilha. O **ALE** (cap. 20) é o remédio direto para o que este relatório contou: condicionamento local respeita o funil em vez de atravessá-lo. O

SHAP condicional é o remédio do lado da atribuição. Do lado das armadilhas, o **PDP** (cap. 19) e a **importância por permutação** (cap. 23) são os próximos a serem medidos com a mesma régua — e a segunda tem, nesta base, uma armadilha pronta: um par de colunas redundante por construção, entre as quais a importância se divide de forma arbitrária. A pergunta que abre o curso e o fecha continua sendo a mesma: **quem são as linhas que você acabou de dar de comer ao modelo?**

Referências

- Baqui, P., Marra, V., Alaa, A. M., Bica, I., Ercole, A., & van der Schaar, M. (2021). Comparing COVID-19 Risk Factors in Brazil Using Machine Learning: The Importance of Socioeconomic, Demographic and Structural Factors. *Scientific Reports*, 11, 15591. <https://doi.org/10.1038/s41598-021-95004-8>
- Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., van Smeden, M., & others. (2024). TRIPOD+AI Statement: Updated Guidance for Reporting Clinical Prediction Models that Use Regression or Machine Learning Methods. *BMJ*, 385, e078378.
- Dandl, S., Molnar, C., Binder, M., & Bischl, B. (2020). Multi-Objective Counterfactual Explanations. *Parallel Problem Solving from Nature (PPSN XVI)*. <https://arxiv.org/abs/2004.11165>
- Garreau, D., & von Luxburg, U. (2020). Explaining the Explainer: A First Theoretical Analysis of LIME. *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS)*. <https://proceedings.mlr.press/v108/garreau20a.html>
- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation. *Journal of Computational and Graphical Statistics*, 24(1).
- Kahn, M. G., Callahan, T. J., Barnard, J., Bauck, A. E., Brown, J., Davidson, B. N., & others. (2016). A Harmonized Data Quality Assessment Terminology and Framework for the Secondary Use of Electronic Health Record Data. *eGEMS (Generating Evidence and Methods to Improve Patient Outcomes)*, 4(1). <https://doi.org/10.13063/2327-9214.1244>
- Knab, P., Marton, S., Schlegel, U., & Bartelt, C. (2025). Which LIME should I trust? Concepts, Challenges, and Solutions. *World Conference on Explainable Artificial Intelligence (XAI)*. <https://arxiv.org/abs/2503.24365>
- Knight, S. R., Ho, A., Pius, R., Buchan, I., Carson, G., Drake, T. M., & others. (2020). Risk Stratification of Patients Admitted to Hospital with COVID-19 Using the ISARIC WHO Clinical Characterisation Protocol: Development and Validation of the 4C Mortality Score. *BMJ*, 370, m3339.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural*

- Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/1705.07874>
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2. <https://doi.org/10.1038/s42256-019-0138-9>
- Marcolino, M. S., Pires, M. C., Ramos, L. E. F., Silva, R. T., Oliveira, L. M., Carvalho, R. L. R., & others. (2021). ABC2-SPH Risk Score for In-Hospital Mortality in COVID-19 Patients: Development, External Validation and Comparison with Other Available Scores. *International Journal of Infectious Diseases*. <https://doi.org/10.1016/j.ijid.2021.07.049>
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.^o ed.). <https://christophm.github.io/interpretable-ml-book/>
- Mothilal, R. K., Sharma, A., & Tan, C. (2020). Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*. <https://doi.org/10.1145/3351095.3372850>
- Ranzani, O. T., Bastos, L. S. L., Gelli, J. G. M., Marchesi, J. F., Baião, F., Hamacher, S., & Bozza, F. A. (2021). Characterisation of the First 250 000 Hospital Admissions for COVID-19 in Brazil: A Retrospective Analysis of Nationwide Data. *The Lancet Respiratory Medicine*, 9(4), 407–418.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. <https://arxiv.org/abs/1602.04938>
- Shapley, L. S. (1953). A Value for n-Person Games. Em *Contributions to the Theory of Games II: Contributions to the Theory of Games II*. Princeton University Press.
- Slack, D., Hilgard, S., Jia, E., Singh, S., & Lakkaraju, H. (2020). Fooling LIME and SHAP: Adversarial Attacks on Post Hoc Explanation Methods. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*. <https://doi.org/10.1145/3375627.3375830>
- Štrumbelj, E., & Kononenko, I. (2014). Explaining Prediction Models and Individual Predictions with Feature Contributions. *Knowledge and Information Systems*, 41(3).
- van Geloven, N., Swanson, S. A., Ramspek, C. L., Luijken, K., Diepen, M. van, Morris, T. P., Groenwold, R. H. H., van Houwelingen, H. C., Putter, H., & le Cessie, S. (2020). Prediction Meets Causal Inference: The Role of Treatment in Clinical Prediction Models. *European Journal of Epidemiology*, 35, 619–630. <https://arxiv.org/abs/2004.06998>
- Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. *Harvard Journal of Law and Technology*, 31(2). <https://arxiv.org/abs/1711.00399>
- Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A Tool to Assess the Risk of Bias and Applicability of Prediction Model Studies. *Annals of Internal Medicine*, 170(1), W1–W33.
- Wynants, L., Van Calster, B., Collins, G. S., Riley, R. D., Heinze, G., Schuit, E., & others. (2020). Prediction Models for Diagnosis and Prognosis of COVID-19: Systematic Review and Critical Appraisal. *BMJ*, 369, m1328.