

Um paciente, cinco perguntas

William Bendinelli

Instituto de Ciências Matemáticas e de Computação · USP

Resumo

Este relatório explica, para um único paciente, o modelo de óbito por COVID do curso, treinado sobre a base de vigilância SRAG/SIVEP-Gripe. Usa os cinco métodos locais estudados nos módulos 01 a 05: perfis *ceteris paribus*, ICE, LIME, contrafactuais e SHAP. Quatro deles são agnósticos de modelo, isto é, explicam por fora, sem abrir a caixa; o SHAP também tem uma versão assim, mas aqui roda pela versão que lê as árvores por dentro. Locais todos, porque explicam uma predição sobre uma pessoa, e não o modelo inteiro. Em vez de cinco estudos avulsos, o mesmo paciente, escolhido por uma regra, atravessa os cinco, e cada método é julgado por uma pergunta clínica que deveria responder.

Dois achados organizam o texto. O primeiro é que a ficha do SIVEP desliga campos: quando ela declara que não há fator de risco, as comorbidades nem chegam a ser apresentadas a quem preenche. Mexer numa variável de cada vez produz então fichas que o formulário não permitiria, e nesta base essa quantidade não é estimada, é contada. O segundo é que o modelo aprendeu com os anos em que se morria muito mais e prevê num mundo em que se morre menos, e a mesma queda reaparece em cinco lugares: na base, na calibração do modelo, no feixe do ICE, no posto do SHAP e nos contrafactuais. Todo número em prosa é impresso por uma célula de caderno versionada, e a nota que o acompanha diz onde essa célula vive.

Palavras-chave: interpretabilidade, SRAG/SIVEP-Gripe, *ceteris paribus*, ICE, LIME, contrafactuais, SHAP

1. Introdução

Um método de interpretabilidade **agnóstico de modelo** explica o modelo por fora. Não abre a caixa: não lê coeficientes, não percorre árvores, não olha pesos. Faz o que qualquer usuário faria: muda o que entra e observa o que sai. Por isso serve igualmente para uma regressão logística e para o comitê de árvores deste relatório. Quatro dos cinco métodos aqui são assim de ponta a ponta; o quinto, o SHAP, é agnóstico na definição, mas para árvores existe uma implementação que percorre a árvore, e é ela que este relatório usa.

Local é a outra metade do nome. Um método global descreve o modelo inteiro, o que ele faz em média sobre a população toda; um método local explica **uma** predição, sobre **um** paciente. É a diferença entre "o que este modelo faz em geral" e "por que ele disse isto sobre esta pessoa".

O modelo aqui prevê óbito hospitalar por COVID a partir das variáveis de admissão da ficha de Síndrome Respiratória Aguda Grave (SRAG). No teste de 2024 ele faz AUC 0,7644.¹ Isso se lê assim: tome um paciente que morreu e outro que sobreviveu, e o modelo ordena os dois corretamente nessa fração das vezes. Uma AUC diz o quanto o modelo acerta; não diz em quem, nem por quê. Para um comitê que decide sobre um paciente, essa é a distância entre uma estatística e uma resposta.

Os cinco métodos locais do curso existem para essa pergunta, e aqui todos caem sobre o mesmo modelo, sob uma restrição que muda a leitura: é sempre **o mesmo paciente**. Na ordem em que foram estudados:

o perfil *ceteris paribus* (e se a idade fosse outra?), o ICE (os outros pacientes respondem igual?), o LIME (por que esta predição, localmente?), os contrafactuais (o que teria de mudar?) e o SHAP (quanto cada variável pesou?).

Dois fatos atravessam as cinco seções. O primeiro: a ficha do SIVEP desliga campos. Quando ela registra que não há fator de risco, as treze comorbidades nem chegam a ser apresentadas a quem preenche; não ficam em branco por descuido, não são feitas. Então mexer numa variável de cada vez, deixando as outras paradas, que é o que os cinco métodos fazem, produz fichas que o formulário não permitiria, e nesta base dá para **contar** quantas. Uma regra dessas é uma **cerca**; uma linha que a atravessa é um **paciente impossível**.

O segundo: o mundo mudou no meio. O modelo aprendeu com os anos de 2020 a 2022, quando se morria muito mais, e prevê em 2024, quando a letalidade observada já caíra quase pela metade. Isso é a **deriva de regime**, e ela deixa marca em cinco lugares deste relatório: na base, na calibração do modelo, nas curvas do ICE, no posto do SHAP e nos contrafactuais. Um achado só, visto por cinco instrumentos.

Vale aqui a regra de evidência do repositório: todo número em prosa é impresso por uma célula de caderno versionada, e as notas de rodapé deste texto dizem onde cada uma vive.

2. O caso: a base, o tratamento e o modelo

A fonte é o SIVEP-Gripe, o sistema com que o Ministério da Saúde vigia a Síndrome Respiratória Aguda Grave:

¹Módulo 00: a AUC do modelo do curso no teste de 2024, lido uma vez só e depois de a escolha estar fechada.

cada internação por SRAG no país vira uma ficha. São 4.109.567 notificações entre 2019 e 2024.²

O tratamento tem três camadas, e a fronteira entre elas é uma pergunta. O **Bronze** é o dado como foi baixado, byte a byte, nunca alterado: é o que foi publicado? O **Prata** afirma fatos sobre o registro, o tipo de cada campo, os valores que ele admite e os três jeitos diferentes de um campo estar vazio: esse valor está determinado pelo registro sozinho? O **Ouro** faz as escolhas da tarefa, com dono e data: o alvo, a coorte, a janela, a divisão treino/teste e a codificação. Esse valor depende do que se quer prever?

A separação não é estética. Enquanto o alvo não é escolhido, nada no tratamento depende do que se quer prever, e um único Prata serve a todos os módulos do curso. Trocar de alvo não refaz a limpeza.

Aqui o alvo é o óbito entre os casos já fechados, e a coorte é a dos hospitalizados com COVID. Ela sai de um funil de seis filtros, publicado na ordem em que os filtros correm, porque as contagens não comutam: cada “restam tantos” só significa alguma coisa se estiver dito o que saiu antes. Ao fim do funil resta a coorte sobre a qual os cinco métodos trabalham.

A divisão entre treino, validação e teste é temporal, e não sorteada, porque a população não é estacionária: em tempo normal a SRAG é doença de criança, e sob COVID é doença de idoso. Sortear linhas misturaria os regimes entre treino e teste, e o modelo seria avaliado nos mesmos anos em que aprendeu. A queda de letalidade sumiria da avaliação em vez de aparecer nela, e o número medido ficaria melhor do que o de uso. O treino vai até 2022, a validação é 2023 e o teste é 2024.

Na fronteira dessa divisão está o achado que os cinco módulos vão explicar: a letalidade observada cai quase pela metade do treino para o teste. Não é um incômodo a corrigir: é o mundo tendo mudado enquanto os dados eram coletados.

O modelo, escolhido por protocolo

O modelo do curso não foi escolhido por gosto. Antes de qualquer leitura do teste, um protocolo foi escrito e versionado: vence a maior AUC na validação de 2023, e o teste é lido uma vez, depois da escolha, sem poder desfazê-la. Seis famílias concorreram, do modelo constante ao XGBoost, e venceu o XGBoost, com os hiperparâmetros que o próprio estudo ajustou. A regressão logística fica ao lado como termo de comparação, e a

distância entre as duas é o problema que este curso existe para resolver.

No teste de 2024 o modelo prevê 0,2154 de risco médio de óbito onde se observa 0,1824.³ Essa diferença entre o que o modelo espera em média e o que de fato aconteceu é o **erro de calibração**: a deriva de regime por dentro do modelo, que aprendeu letalidades antigas e encontrou outro mundo. A capacidade de ordenar pacientes sofre junto, embora menos.

As quatro impossibilidades

Quatro regras da ficha proíbem combinações de valores, e são as quatro cercas desta base. De cada uma se mede a mesma coisa: a fração da amostra que está **em cima** da fronteira, aquela para quem uma única perturbação já cai do lado impossível.

O portão do funil. A ficha desliga as treze comorbidades quando o campo de fator de risco declara que não há nenhum. Marcar uma comorbidade num paciente nesse estado contradiz um portão que, medido nos seis anos da base, nunca foi contrariado.

A pré-campanha. A campanha de vacinação tem data de início. Quem adoeceu antes dela não pode ter tomado dose nenhuma, e aumentar a contagem de doses inventa uma vacina que ainda não existia.

O critério-2 por um fio. A definição de SRAG exige ao menos um sintoma de cada um de dois grupos: tosse ou dor de garganta; falta de ar, queda de saturação ou desconforto respiratório. Quem entrou marcando **um só** dos dois sintomas do primeiro grupo está por um fio: desligar esse sintoma o tira da definição de caso, e um paciente fora da definição não estaria na base. É o estado mais comum da amostra, de longe.


O critério-3 por um fio. O mesmo, no segundo grupo, com três sintomas em vez de dois e bem menos gente pendurada nele.

Perturbar uma linha através de qualquer dessas fronteiras fabrica um paciente que não pode existir. Os cinco módulos fazem essa conta pela **mesma** função que conta o impossível (`gate_impossible`), o que torna os números idênticos por construção. Quem é esse paciente, e por que uma regra o escolheu, é a próxima seção.

3. O paciente e as três cercas

Quem é o paciente

O paciente deste relatório não foi escolhido a dedo. Ele veio de uma regra escrita antes de olhar: entre todos



a barreira: a função que escolhe o modelo levanta uma exceção se enxergar o teste

Figura 1. O protocolo que escolheu o modelo do curso: os candidatos aprendem no treino, a escolha acontece na validação, e o teste é lido uma vez, depois dela. A barreira do meio é código, não promessa: a função que escolhe o modelo levanta uma exceção se enxergar o teste. A figura ensina o desenho do estudo; o placar com todos os candidatos vive no módulo 00.

²Módulo 00: a contagem de fichas do extrato congelado que serve a todo o curso; ele é datado porque a ficha muda entre versões.

³Módulo 00: o risco médio que o modelo prevê no teste de 2024, ao lado da letalidade que de fato se observou nesse ano.

os pacientes do ano de teste, aquele cuja predição cai mais perto da fronteira da decisão, com o identificador servindo de desempate.

O escolhido, pela regra do módulo 00, é um homem de 90 anos, do Sudeste, que adoeceu na semana 34 de 2024, com uma dose de vacina antes do sintoma e cardiopatia declarada. Ele é o **paciente-regra**, e as cinco perguntas deste relatório são feitas sobre ele.

Estar em cima da fronteira não é acaso conveniente: é a condição que torna as cinco respostas comparáveis. É ali que a reta local do LIME não degenera numa constante e que as forças do SHAP se cancelam de forma legível. Um paciente confortavelmente de um lado só esconderia o que cada método faz quando é obrigado a decidir.

Dois outros aparecem, cada um com uma razão declarada. Os módulos 01 e 03 usam um segundo, escolhido pela mesma regra mas restrito a quem está exposto às três cercas, chamado aqui de **vulnerável**: ele existe para mostrar que a quantidade de ficção que um método fabrica depende de **quem** está sendo explicado. O módulo 04 precisa de um terceiro, com predição bem mais alta, porque contrafactual pede alguém com o que perder.

A legenda vale em todas as figuras deste relatório: **a forma diz de onde o ponto veio; a cor diz o que ele é**. Círculo é paciente real, colorido pelo desfecho **observado**: azul sobreviveu, terracota morreu. Quadrado é vizinho **sintético**, colorido pela **predição do modelo**. O X escuro é o paciente sendo explicado. No tracejado, escuro e longo é a fronteira do modelo, cinza e médio a vizinhança que um método construiu, claro e curto só andaime de eixo.

A ficha do SIVEP não é um formulário plano: ela **desliga campos**. Quando o campo de fator de risco declara que o paciente não tem nenhum, as treze comorbidades abaixo dele nem chegam a ser apresentadas a quem preenche. O vazio que sobra ali não é dado faltante. É informação: diz que a pergunta não foi feita, e diz por quê.

Por isso o tratamento separa três leituras do vazio: **não se aplica** (o portão desligou o campo), **ausente** (o

campo estava aberto e ficou em branco) e **ignorado** (alguém registrou que não sabe). Fundir as três trans-forma resposta em buraco: o dado faltante cresce sem que nada tenha se perdido, e quem imputa por cima dá comorbidade a quem declarou não ter nenhuma.⁴

Como as features são **conjuntamente restritas**, todo método que perturba uma feature de cada vez fabrica pacientes que não podem existir. As quatro regras da seção anterior viram três cercas nos módulos, porque o critério-2 e o critério-3 são a mesma cerca lida em dois grupos de sintomas: a definição da coorte.

cerca	o que ela proíbe
portão do funil	marcar comorbidade em quem declarou não haver fator de risco
calendário da campanha	dar uma dose a quem adoeceu antes de a campanha começar
definição da coorte	apagar o único sintoma que fez o paciente entrar na coorte

Fonte: módulo 00, MODEL.md; a mesma função nos módulos 01 a 05

E a cerca não é vista pela geometria. A distância de Gower compara duas fichas célula a célula, pondo números e categorias na mesma escala; por ela o ponto impossível fica mais perto de um paciente real do que o paciente real mediano fica do vizinho dele. Trocar um nível de categoria custa o mesmo, seja a troca possível ou impossível: nenhuma checagem por distância pega a contradição.

4. Ceteris paribus: e se a idade fosse outra?

Congela-se o paciente, escolhe-se uma variável e uma **grade** (a lista de valores que ela vai assumir) e plota-se a predição em cada valor. Sem modelo intermediário, sem sorteio, sem aproximação: a curva **é** a saída do modelo (Molnar, 2025), e é por não aproximar nada que o método mais simples do curso expõe o problema que todos os seguintes herdam.

Um modelo de árvores não lê a idade como um valor que escorre: ele pergunta se a idade passou de um corte, depois se passou do seguinte. Entre dois cortes ele não muda de opinião, então a predição fica parada e pula de uma vez. A curva vira uma **escadaria**.




Figura 2. A variável-funil: o campo de fator de risco governa se as comorbidades abaixo dele chegam a ser perguntadas. A figura diz quais respostas são possíveis, não quantos pacientes caem em cada ramo.

⁴Módulo 00: fundir os três estados infla o dado faltante por 1,8× a 5,7× conforme o ano.




Figura 3. O mesmo paciente em dois modelos, na idade e nas doses: a escadaria do modelo do curso contra a rampa da logística. Nenhuma das curvas diz o que aconteceria se este paciente tomasse mais uma dose; o perfil prevê, não intervém.

E a escadaria se lê errado com facilidade. Numa grade grossa, a altura de um degrau é propriedade da grade: cada salto visível soma vários saltos verdadeiros, e pedir a predição em idades mais próximas parte o degrau grande em degraus menores. Mas o refino tem fim. A partir de certo passo os degraus param de encolher, e a altura que sobra é do modelo.⁵ A amplitude, do ponto mais alto ao mais baixo, não se move em refino nenhum. Leia posições de corte primeiro, e só leia altura de degrau depois que refinar a grade tiver parado de mudá-la.

A logística não tem interações, e o efeito disso é a forma: ela desenha a mesma curva em S para **todo** paciente. O resto da ficha entra somando, e uma soma feita antes de a conta virar probabilidade desliza a curva ao longo do eixo em vez de levantá-la. Dois pacientes diferem em **onde** ela sobe, não em como sobe, e no trecho que o gráfico mostra isso muda a altura e a inclinação ao mesmo tempo. O modelo do curso desenha uma curva com forma própria por paciente, e é daí que sai o ganho que nenhum coeficiente global exhibe. Nas doses os dois discordam de ponta a ponta⁶, e aí mora uma armadilha: dizer que o modelo do curso “desce nas doses” é ler a ponta do gráfico, não o paciente, porque perto do próprio paciente a inclinação é **positiva**.

A resposta, e o preço. Para a pergunta do título o método responde direto, lendo a curva de idade no valor que interessa. E responde barato: sem sorteio no caminho, repetir a conta devolve a mesma curva. O preço é que a resposta vale para uma linha fabricada, e quanto dela é ficção depende de quem se explica: para o paciente-regra nenhuma das oito variáveis de maior peso fabrica um impossível; para o vulnerável, a mesma varredura é ficção do começo ao fim. A concentração da ficção é propriedade da coorte, não do método.

5. ICE: os outros respondem igual?

O ICE desenha um perfil *ceteris paribus* por paciente, todos no mesmo eixo (Goldstein et al., 2015). Esse conjunto de curvas é o **feixe**, e o que ele acrescenta é

heterogeneidade: o modelo trata todos do mesmo jeito? O teste do capítulo é de olho nu: se todas as curvas seguem o mesmo curso, o modelo ajustado não tem interação naquela variável, e a média delas, o **PDP**, basta.

Uma curva por paciente significa que, com a base inteira, o gráfico vira uma mancha preta: é o amontoamento (**overcrowding**) de que o capítulo avisa. Por isso se sorteia um subconjunto, e a regra do sorteio se declara.⁷ A **semente** é o número que fixa o sorteio: quem rodar o caderno de novo obtém as mesmas curvas, e é isso que torna a figura reproduzível. **Estratificar por ano** é tirar a mesma quantidade de pacientes de cada ano; sem estrato, 2020–2022 dominaria a amostra e o regime sumiria no desbalanceio.

Está aí a lição do PDP: a média fica entre duas populações e não descreve nenhuma.⁸ **Centrar** as curvas confirma: subtraído de cada uma o valor que ela tem no início da grade, todas partem do zero e sobra só a forma, quase paralela, com os pacientes subindo do mesmo jeito de níveis muito diferentes. O PDP acerta a forma e erra o nível de todos ao mesmo tempo, o modo de mentir mais educado que existe.

A **derivada** é a inclinação da curva, e numa escadaria ela não existe em cada ponto: o que o caderno desenha é a diferença entre dois pontos vizinhos da grade, que aqui distam um ano. Lida assim, ela diz quanto a predição muda por um ano a mais, na grade usada. Ela acha o efeito onde ninguém procurava, num pico pediátrico. Não é biologia: é o modelo lendo uma coorte em que a SRAG pediátrica pré-COVID era bronquiolite.

A resposta, e o preço. Não, os outros não respondem igual, e a diferença é o ano em que adoeceram. O preço é que a ficção se multiplica por duzentas curvas e continua contável: o feixe de idade não tem um ponto impossível, o de doses fabrica 18% e o de tosse, 54%.⁹ A variável varrida decide se o feixe é retrato ou fábula.

6. LIME: por que esta predição, localmente?

O LIME (Ribeiro et al., 2016) não abre o modelo. Ele fabrica vizinhos artificiais em volta do paciente, pergunta

⁵Módulo 01: em quatro refinamentos da grade de idade a amplitude fica em 0,4809 e o maior salto cai de 0,1387 para 0,0852, e aí não cede mais.

⁶Módulo 01, walkthrough §1b: a fig. 12.5 do livro, refeita. Nas doses a logística sobe 0,217 e o modelo do curso termina 0,044 abaixo.

⁷Módulo 02: o feixe sorteia 200 pacientes, 40 por ano, com semente 42.

⁸Módulo 02, walkthrough §1: aos 80 anos o feixe vale 0,481 em 2020 e 0,303 em 2024, e o PDP reporta 0,400.

⁹Módulo 02: 252 dos 1.400 pontos do feixe de doses caem antes de a campanha começar, uma fração derivável antes mesmo de medida.




Figura 4. Olhe a rampa de intensidade: quanto mais escura a curva, mais letal o regime em que o paciente adoeceu, e as de 2020 correm por cima das de 2024, então o teste do capítulo falha de propósito. A figura não mostra efeito da idade: cada ponto é a predição numa linha fabricada.

ao modelo o que ele prevê em cada um, dá mais peso aos mais parecidos e ajusta uma reta simples nesse conjunto. Essa reta é o **substituto**: imita o modelo complicado só ali perto, e seus coeficientes são a explicação. O **kernel** decide o peso de cada vizinho conforme a distância, e a largura dele define o tamanho de "ali perto".

O substituto nunca passa por cima do modelo. A predição continua vindo do XGBoost; a reta só a resume.

Três surpresas estão na figura. A nuvem não está centrada no paciente: o gerador padrão a centra na média do treino, e o paciente fica a vários desvios do centro da própria "vizinhança". O kernel descarta quase tudo, e sobram poucos vizinhos com peso apreciável. E é nesse deserto que a reta é ajustada.

A vizinhança tem dois defeitos, e só um tem conserto fácil. Declarar quais colunas são discretas conserta a **gramática**: a nuvem para de produzir códigos que não existem na ficha e doses negativas, e nada avisava,




Figura 5. Os seis passos do método sobre um corte ceteris paribus do modelo do curso: fronteira, vizinhança, perturbação, predições, pesos e reta. Só o painel D consulta o modelo. A figura não mostra uma vizinhança de pacientes: cada coluna da nuvem é sorteada sozinha.

porque a função que entrega os vizinhos ao modelo arredonda em silêncio. Não conserta a **biologia**: cada coluna continua sorteada sozinha, a correlação entre calendário e doses some, e os vizinhos impossíveis continuam lá, quase um terço dos do paciente-regra e quatro em cada cinco dos do vulnerável.¹⁰

A resposta, e o preço. O LIME dá um ranking com sinal, e o topo dele é firme entre sementes: no módulo 03, dez delas dão o mesmo top-5, sem troca de sinal no top-8. O preço é o R^2 : ele mede o quanto a reta reproduz a nuvem ponderada, não a **fidelidade local**, o quanto a explicação acerta neste paciente. Com kernel estreito o substituto degenera na constante certa e entrega R^2 zero com erro zero, a explicação vazia perfeita; com kernel largo, R^2 e erro sobem juntos.¹¹ Nenhuma largura compra as duas, e o capítulo é franco: definir a vizinhança certa é problema em aberto (Molnar, 2025). A regra que sobra é dura: não ranquee explicações por R^2 . A amostragem fora da variedade abre ainda um ataque (Slack et al., 2020): os vizinhos sorteados não se parecem com pacientes reais, então dá para treinar um detector que os reconheça. Um modelo montado com esse detector responde aos vizinhos com uma cara inocente e segue enviesado nos pacientes de verdade, e o LIME explica a cara, não o modelo.

7. Contrafactuais: o que teria de mudar?

Os três métodos anteriores perguntam “o que pesou?”. O contrafactual inverte: qual é a menor mudança que muda a saída? Com isso, as cercas deixam de ser diagnóstico de método doente e viram **restrição de busca**.

A ideia vem de Wachter et al. (2018): a menor mudança na ficha que leva o modelo à saída desejada, sem abrir a caixa. A perda que eles escrevem pesa duas coisas, chegar à saída e ficar perto do original. Como a saída é um paciente hipotético, o campo foi somando

exigências depois, e o capítulo de Molnar as reúne (Molnar, 2025): **validade**, a mudança cruza mesmo o limiar; **proximidade**, o hipotético fica perto do real; **esparsidade**, mudam poucas coisas; **plausibilidade**, ele poderia existir; **diversidade**, há mais de um caminho.

O módulo não usa biblioteca, e a razão é uma boa lição de engenharia: o espaço de mudanças declarado cabe inteiro na memória, então o caderno enumera todas em vez de otimizar a perda de Wachter. Isso compra cobertura completa, determinismo sem semente e custo de milissegundos. O paciente aqui não é o paciente-regra: o módulo 04 pede alguém com o que perder, e caiu num paciente de 32 anos, com quatro doses, síndrome de Down, doença neurológica, imunodepressão e doença renal.

O gradiente é a leitura difícil da figura: quem mais precisaria de uma saída é exatamente quem não tem nenhuma.¹² E a busca livre explica: a melhor mudança única que ela encontra é apagar do prontuário a saturação baixa, **consequência** da doença e não alavanca; atrás dela vêm voltar a ter 10 anos e recuar o calendário para o começo da pandemia.

Três histórias sem um ingrediente em comum levam o paciente para o lado certo do limiar, e param em predições bem diferentes: o efeito Rashomon impresso, explicações diferentes e igualmente válidas para o mesmo caso. Qual delas se contaria ao paciente?

A resposta, e o preço. A resposta honesta é **não há**: os dois candidatos ao alcance deste paciente não movem a predição. Um método que só sabe prescrever precisa saber dizer isso. O preço tem duas partes. Válido não é alcançável: os melhores candidatos passam na cerca, mas pedem uma máquina do tempo. E a plausibilidade se decide sobre o candidato inteiro, não sobre




Figura 6. Cada barra é uma banda de risco, e a altura é a fração de pacientes dessa banda para quem algum movimento ao alcance de uma pessoa cruza o limiar: olhe o gradiente, que desce conforme o risco sobe. Barra nenhuma não é paciente condenado, nem a figura mede eficácia: é o método sem o que prescrever.

¹⁰Módulo 03, walkthrough §4: a contagem de impossíveis reprova 30,6% dos vizinhos sorteados em torno do paciente-regra e 79,2% dos do vulnerável.

¹¹Módulo 03, walkthrough §5: o kernel estreito mede R^2 0,00 com erro 0,00, e o largo, R^2 0,68 com erro 0,028.

¹²Módulo 04, walkthrough §5: dos 624 pacientes de alto risco, 30,3% têm contrafactual acionável, e a fração cai conforme o risco sobe.




Figura 7. Um cabo de guerra que empata: a idade empurra para cima, a vacinação declarada e o calendário freiam, e o que se olha é a soma, que cai exatamente sobre a margem deste paciente. A figura não é um contrafactual: reparte o que já aconteceu.

o movimento: recuar o calendário sozinho cai na cerca da campanha, recuá-lo com zero doses não cai.

8. SHAP: quanto cada feature pesou?

O SHAP (Lundberg & Lee, 2017) responde repartindo, e a regra de partilha vem de um teorema sobre jogos (Shapley, 1953). A predição deste paciente é o resultado da partida; o ganho é a diferença entre ela e a predição média, a de quem nada sabe sobre ele; os jogadores são os valores das variáveis. O valor de Shapley reparte esse ganho entre eles de forma que a soma feche. Em árvores, o TreeSHAP (Lundberg et al., 2020) faz a conta de forma exata em vez de aproximá-la, e o modelo do curso já a traz pronta (`pred_contribs`). Aqui cai a única exceção do relatório. O valor de Shapley é agnóstico de modelo, e existe uma versão dele que trata qualquer modelo como caixa fechada, o KernelSHAP (Lundberg & Lee, 2017). O TreeSHAP não é: ele percorre as árvores. Troca-se a generalidade pela conta exata e barata, e a troca fica dita em vez de escondida.

Antes da figura, a escala. As contribuições vivem na **margem**: o número que o modelo soma por dentro e que só depois vira probabilidade. É aí que somar as contribuições das 800 árvores do módulo 00 faz sentido; somar probabilidades não faria, porque elas saturam nas pontas.

Que a soma feche é o que separa o SHAP dos outros quatro métodos: aqui não há ajuste que possa sair bom ou ruim, como o R^2 do LIME. As parcelas fecham porque um axioma manda, a eficiência, e a garantia vira verificação, conferida linha a linha no teste inteiro.¹³

O que a figura **não** significa é causa. Um ϕ positivo não diz que aumentar aquela variável aumentaria a predição, e também não é o que sobra quando se apaga a

variável do modelo. Ele é uma média: monte o paciente variável por variável, em todas as ordens possíveis, e anote quanto a predição se move no instante em que **esta** entra. O ϕ é a média dessas anotações, contada a partir da predição de quem nada sabe sobre o paciente. Não é o efeito daquele valor com o resto da ficha parado. E o modelo dá o caso que quebra: o ϕ das doses de vacina é **positivo** nos vacinados. Não porque vacina mate. O crédito protetor mora na variável colinear, a que declara a vacinação, e o que sobra para a contagem de doses é marcar os grupos priorizados na campanha. O antídoto está no módulo anterior: subir as doses deste paciente quase não move a predição.

Duas medições fecham o arco. A primeira liga o SHAP à deriva de regime: a variável de calendário está entre as primeiras para mover as predições de 2024 e cai para o meio da tabela pelo ganho das divisões (*gain*), a medida de quanto ela ajudou a construir as árvores. Pela atribuição ela é terceira; pelo ganho é a 19ª de 40.¹⁴ Importância para prever não é importância para treinar.

A segunda é o preço do condicionamento. Apagar uma variável para medir o que ela vale tem duas versões: seguir os caminhos que as árvores percorrem de fato, respeitando as correlações aprendidas, ou apagá-la mesmo, montando pacientes que são metade este e metade outro. As direções batem; as magnitudes divergem onde as correlações moram. O caminho das árvores também cobra o seu: ao respeitar as correlações, ele pode dar crédito a uma variável que o modelo nem usa, só porque ela anda junto de uma que usa (Molnar, 2025).

A resposta, e o preço. O SHAP responde a última das cinco perguntas com números que somam, e é a única

¹³Módulo 05, internals §1: as 40 contribuições mais a base reproduzem a margem com desvio máximo $1,05 \times 10^{-5}$ nas 16.142 linhas do teste.

¹⁴Módulo 05, walkthrough §4: 19ª de 40 pelo ganho do treino, contra a terceira colocação por média $|\phi|$ no teste de 2024.

¹⁵Módulo 05, walkthrough §7: 23,1% das 2.460 linhas híbridas montadas pela variante intervencional são impossíveis.




Figura 8. O painel-armadilha é o da direita: quem não declarou dose recebe crédito negativo; as doses declaradas recebem crédito positivo. Ele não compara vacinado com não vacinado, nem mede efeito de vacina: mostra como o modelo divide crédito entre variáveis que andam juntas.

resposta auditável do relatório. O preço é a segunda versão: os pacientes que ela monta são híbridos, e quase um quarto deles não pode existir, pela mesma função que conta o impossível nos outros módulos.¹⁵ A limitação que o livro-texto enuncia fica contada, em vez de citada.

9. As cercas, lado a lado, e a deriva

Os cinco módulos contaram a mesma coisa com cinco instrumentos, e sempre pela mesma função, escrita uma vez no módulo 00 e importada pelos cinco cader-nos. A tabela compara métodos, não implementações.

método	o que foi contado	fração
módulo 01	pacientes da amostra para quem marcar comorbidade cairia no portão	37,3%
módulo 01	pacientes da amostra que entraram na coorte por um sintoma só	79,6%
módulo 02	pontos do feixe de doses, onde a cerca é da variável	18%
módulo 03	vizinhos sorteados em torno do paciente-regra	30,6%
módulo 03	os mesmos vizinhos, em torno do vulnerável	79,2%
módulo 04	candidatos a contrafactual, uma célula por vez	3,5%
módulo 05	linhas híbridas montadas pela variante intervencional	23,1%

Fonte: walkthrough §2 (01), §3 (02), §4 (03), §2 (04) e §7 (05)

A tabela junta, de propósito, duas contas diferentes. As duas primeiras linhas medem **exposição da coorte**: quantos pacientes reais já estão em cima de uma cerca, antes de qualquer método rodar. As outras cinco medem **ficção do método**: quantos dos pontos que o método fabricou não podem existir. A primeira conta é do mundo; a segunda é do instrumento. E a tabela não é um ranking de qualidade. A taxa de ficção é propriedade conjunta de três coisas: o método, a variável perturbada e **quem** está sendo explicado. O contrafactual fabrica pouco porque parte de um paciente real e move uma célula por vez. O LIME fabrica muito porque sorteia todas as colunas de uma vez, e fabrica mais que o dobro no vulnerável, pelo mesmo gerador, já que a nuvem nem olha para o paciente.

A deriva, vista por cinco instrumentos

Não são cinco achados, é um só, visto de cinco ângulos. Ele nasce na base: no módulo 00, a letalidade bruta anual cai de 29,0% em 2020 para 8,6% em 2024. O modelo herda a queda como erro de calibração, porque aprendeu num mundo mais letal e prevê morte demais no atual.¹⁶ O ICE dá rosto ao erro, com duas alturas para a mesma idade quando o feixe é estratificado por ano. O SHAP dá um posto: o calendário é das primeiras variáveis por atribuição e fica no meio da tabela pelo ganho na construção das árvores. E o contrafactual mostra o lado perverso: os melhores candidatos válidos pedem que o paciente volte ao começo da pandemia.




Figura 9. O que olhar é a cor das barras: a mesma varredura de doses, na mesma grade restrita, sobrevive inteira no paciente pós-campanha e é barrada quase toda no pré-campanha, onde só a dose zero podia ter existido. A figura não mostra efeito de vacina; mostra em quais pontos a pergunta podia ser feita. É assim que o remédio do capítulo funciona, dizendo **quando não perguntar**.

¹⁶Módulo 00, MODEL.md: no teste, o modelo prevê 0,2154 onde se observa 0,1824.

Uma explicação que revela “ano” está, portanto, **correta**. O modelo aprendeu o regime, e escondê-lo seria pior do que mostrá-lo.

10. Limitações, discussão e o que aprendemos

O que os métodos não dizem

Nenhum dos cinco entrega causalidade. Todos leem um modelo treinado em fichas de vigilância, e uma ficha registra **documentação** tanto quanto biologia. O resultado de imagem demonstra isso: usá-lo melhoraria a AUC, e o sinal viria invertido, com quem tem exame registrado morrendo menos. Não é pulmão, é documentação vazando no rótulo.

A mesma lógica explica a exclusão mais discutida do Ouro. Admissão em UTI e suporte ventilatório são os dois campos clinicamente mais fortes da ficha, e somá-los subiria bastante a AUC.¹⁷ Ficam fora mesmo assim, e o critério não é o tamanho do ganho: é o **instante da predição**. A ficha só os preenche no encerramento da internação, no mesmo ato que digita o desfecho, então usá-los é prever a admissão com informação que ainda não existia. Isso infla o desempenho aparente sem tornar o modelo utilizável (Wolff et al., 2019).

Há ainda o confundimento por capacidade instalada: quem foi ventilado depende de haver leito, e a oferta de leitos era desigual entre as regiões brasileiras. Mover a ventilação num perfil ceteris paribus não mostraria efeito de tratamento, mostraria triagem. Aquele número maior não é um modelo melhor da mesma pergunta; é um modelo de outra pergunta.

O que os dados ensinaram sobre os métodos

A lição principal inverte a direção habitual: em vez de usar o método para entender os dados, foram os dados que qualificaram o método. Numa base cuja estrutura de formulário é conhecida, a advertência de Molnar, de que perturbar variáveis de forma independente cria combinações irreais, vira contagem.

A segunda lição veio de um acidente. Quando o estudo de seleção trocou os hiperparâmetros do modelo do curso, os cinco módulos foram re-sincronizados afirmação por afirmação, e deu para ver **que tipo** de frase sobrevive. Caíram quase só leituras de ponta e narrativas bonitas; sobreviveram as contagens de cerca, que não se moveram, porque medem a base e não o modelo. Vale escrever cada frase sabendo de qual das duas se trata.

O que evitar

- **Prosa editada por busca-e-substituição.** Quando o modelo muda, o número muda e a afirmação pode cair junto.
- **Número sem célula que o imprima.** Ou a célula existe, ou o número sai da prosa.
- **Ler a figura em vez da célula.** O gráfico sugere onde a curva vira; a célula diz onde ela vira.
- **PDP lido como “o” efeito.** A média de um feixe não descreve regime nenhum.
- **φ positivo lido como causa.** Ele diz o que o modelo creditou àquele valor, não o que aconteceria se o valor mudasse.

O que torna este relatório verificável não é o texto, é a regra: todo número em prosa é impresso por uma célula versionada, a frase que o carrega nomeia o módulo, e um script reprova o arquivo quando isso é quebrado. É barato de manter e caro de fingir. O próximo capítulo é o remédio direto: o ALE condiciona localmente, dentro da vizinhança que a base de fato tem, em vez de atravessar o funil inteiro. E a pergunta que abre o curso e o fecha continua a mesma: **quem são as linhas que você acabou de dar de comer ao modelo?**

Referências

- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation. *Journal of Computational and Graphical Statistics*, 24(1).
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/1705.07874>
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2. <https://doi.org/10.1038/s42256-019-0138-9>
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.º ed.). <https://christophm.github.io/interpretable-ml-book/>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. <https://arxiv.org/abs/1602.04938>
- Shapley, L. S. (1953). A Value for n-Person Games. Em *Contributions to the Theory of Games II: Contributions to the Theory of Games II*. Princeton University Press.
- Slack, D., Hilgard, S., Jia, E., Singh, S., & Lakkaraju, H. (2020). Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 180–186. <https://doi.org/10.1145/3375627.3375830>
- Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. *Harvard Journal of Law and Technology*, 31(2). <https://arxiv.org/abs/1711.00399>
- Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A Tool to Assess the Risk of Bias and Applicability of Prediction Model Studies. *Annals of Internal Medicine*, 170(1), W1–W33.

¹⁷Módulo 00, GOLD.md, decisão 3: com os dois campos, a AUC de teste vai de 0,7644 para 0,8514.