

Um paciente, cinco perguntas

William Bendinelli

Instituto de Ciências Matemáticas e de Computação · USP

Resumo

Cinco métodos locais de interpretabilidade (perfis *ceteris paribus*, ICE, LIME, contrafactuais e SHAP) aplicados a um único paciente e a um único modelo: um XGBoost que prevê óbito hospitalar por COVID a partir da ficha de SRAG do SIVEP-Gripe. O paciente, escolhido por uma regra escrita antes de olhar, atravessa os cinco. Cada método é julgado por duas coisas: a pergunta clínica que deveria responder, e o preço que cobra para responder, medido em quantos pacientes impossíveis ele precisa fabricar pelo caminho.

Palavras-chave: interpretabilidade, SRAG/SIVEP-Gripe, *ceteris paribus*, ICE, LIME, contrafactuais, SHAP

1. Introdução

Um método de interpretabilidade **agnóstico de modelo** explica o modelo por fora. Não abre a caixa: não lê coeficientes, não percorre árvores, não olha pesos. Faz o que qualquer usuário faria: muda o que entra e observa o que sai. Por isso serve igualmente para uma regressão logística e para o comitê de árvores deste relatório. Quatro dos cinco métodos aqui são assim de ponta a ponta; o quinto, o SHAP, é agnóstico na definição, mas para árvores existe uma implementação que percorre a árvore, e é ela que este relatório usa.

Local é a outra metade do nome. Um método global descreve o modelo inteiro, o que ele faz em média sobre a população toda; um método local explica **uma** predição, sobre **um** paciente. É a diferença entre “o que este modelo faz em geral” e “por que ele disse isto sobre esta pessoa”.

O modelo aqui prevê óbito hospitalar por COVID a partir de variáveis disponíveis na admissão da ficha de Síndrome Respiratória Aguda Grave (SRAG), com duas exceções declaradas: a coinfeção viral, que é resultado de laboratório, e o marcador de caso nosocomial. No teste de 2024 ele faz AUC 0,7644.¹ Isso se lê assim: sorteie ao acaso um paciente que morreu e outro que sobreviveu, e o modelo dá risco maior ao que morreu nessa fração das vezes, com um empate valendo meio acerto. Uma AUC diz o quanto o modelo **ordena**; não diz se os riscos que ele imprime estão no nível certo, nem em quem, nem por quê. Para um comitê que decide sobre um paciente, essa é a distância entre uma estatística e uma resposta.

Os cinco métodos locais do curso existem para essa pergunta, e aqui todos caem sobre o mesmo modelo, sob uma restrição que muda a leitura: é sempre **o mesmo paciente**. Na ordem em que foram estudados: o perfil *ceteris paribus* (e se a idade fosse outra?), o

ICE (os outros pacientes respondem igual?), o LIME (por que esta predição, localmente?), os contrafactuais (o que teria de mudar?) e o SHAP (quanto cada variável pesou?).

Dois fatos atravessam as cinco seções. O primeiro: a ficha do SIVEP desliga campos. As treze comorbidades só aparecem preenchidas nos registros em que o campo de fator de risco diz que há algum; onde ele está em branco, o bloco inteiro está em branco junto, e não por descuido: a pergunta não chegou a ser feita. Então mexer numa variável de cada vez, deixando as outras paradas, que é o que os cinco métodos fazem, produz fichas que o formulário não permitiria, e nesta base dá para **contar** quantas. Uma regra dessas é uma **cerca**; uma linha que a atravessa é um **paciente impossível**.

O segundo: o mundo mudou no meio. O modelo aprendeu com os anos de 2020 a 2022, quando se morria muito mais, e prevê em 2024, quando a letalidade da coorte já caíra de 31,4% para 18,2%.² Isso é a **deriva de regime**, e ela deixa marca em cinco lugares deste relatório: na base, na calibração do modelo, nas curvas do ICE, no posto do SHAP e nos contrafactuais. Um achado só, visto por cinco instrumentos.

Vale aqui a regra de evidência do repositório: todo número em prosa é impresso por uma célula de caderno versionada, e as notas de rodapé deste texto dizem onde cada uma vive.

2. O caso: a base, o tratamento e o modelo

A fonte é o SIVEP-Gripe, o sistema com que o Ministério da Saúde vigia a Síndrome Respiratória Aguda Grave: cada internação por SRAG no país vira uma ficha, e também cada óbito por SRAG, mesmo sem internação. São 4.109.567 notificações entre 2019 e 2024.³

O tratamento tem três camadas, e a fronteira entre elas é uma pergunta que se faz a cada valor. O **Bronze**

¹Módulo 00: a AUC do modelo do curso no teste de 2024, lido uma vez só e depois de a escolha estar fechada.

²Módulo 00: a letalidade observada de cada split, treino contra teste, dentro da coorte que o modelo enxerga.

³Módulo 00: a contagem de fichas do extrato congelado que serve a todo o curso; ele é datado porque a ficha muda entre versões.

é o dado como foi baixado, byte a byte, nunca alterado: esse valor veio assim da fonte? O **Prata** afirma fatos sobre o registro, o tipo de cada campo, os valores que ele admite e os três jeitos diferentes de um campo estar vazio: esse valor está determinado pelo registro sozinho? O **Ouro** faz as escolhas da tarefa, com dono e data, o alvo, a coorte, a janela, a divisão treino/teste e a codificação: esse valor depende do que se quer prever?

A separação não é estética. Enquanto o alvo não é escolhido, nada no tratamento depende do que se quer prever, e um único Prata serve a todos os módulos do curso. Trocar de alvo não refaz a limpeza.

Aqui o alvo é o óbito entre os casos já fechados, e a coorte é a dos hospitalizados com COVID. Ela sai de um funil de seis filtros, publicado na ordem em que os filtros correm, porque as contagens não comutam: cada “restam tantos” só significa alguma coisa se estiver dito o que saiu antes. Ao fim do funil resta a coorte sobre a qual os cinco métodos trabalham.

A divisão entre treino, validação e teste é temporal, e não sorteada, porque a população não é estacionária: em tempo normal a SRAG tem duas pontas, um pico pediátrico de casos e um pico idoso de óbitos, e sob COVID o peso se desloca inteiro para o idoso. Sortear linhas misturaria os regimes entre treino e teste, e o modelo seria avaliado nos mesmos anos em que aprendeu. A queda de letalidade sumiria da avaliação em vez de aparecer nela, e o número medido ficaria melhor do que o de uso. O treino vai até 2022, a validação é 2023 e o teste é 2024.

Na fronteira dessa divisão está o achado que os cinco módulos vão explicar: a letalidade observada da coorte cai quase pela metade do treino para o teste. Para este relatório não é um incômodo a corrigir, é o objeto: é o mundo tendo mudado enquanto os dados eram coletados, e são cinco métodos apontados para essa mudança. Para uso clínico seria outra coisa, porque a validação temporal revela a deriva e não a conserta.

O modelo, escolhido por protocolo

O modelo do curso não foi escolhido por gosto. Antes de qualquer leitura do teste, um protocolo foi escrito e versionado: vence a maior AUC na validação de 2023, com modelos dentro de um erro-padrão bootstrap tratados como empatados e a calibração servindo de primeiro desempate, e o teste é lido uma vez, depois da escolha,

sem poder desfazê-la. Aqui não houve empate, então quem escolheu foi a AUC sozinha, e vale dizer o limite: um critério de discriminação é cego para o nível do risco, que é exatamente a dimensão em que o vencedor falha. Seis famílias concorreram, do modelo constante ao XGBoost, e venceu o XGBoost, com os hiperparâmetros que o próprio estudo ajustou. A regressão logística fica ao lado como termo de comparação, e a distância entre as duas é o problema que este curso existe para resolver.


No teste de 2024 o modelo prevê 0,2154 de risco médio de óbito onde se observa 0,1824.⁴ Essa diferença entre o que o modelo espera em média e o que de fato aconteceu é a **calibração-in-the-large**, o degrau mais fraco da calibração: o modelo prevê cerca de um quinto de óbitos a mais do que ocorreram. É a deriva de regime por dentro do modelo, que aprendeu letalidades antigas e encontrou outro mundo.

A capacidade de **ordenar** pacientes não sofre junto, e a distinção é a lição. A AUC é uma medida de posto, invariante a qualquer reescala monótona do risco, então um desvio de nível não a toca. O módulo 00 mede 0,7564 na validação de 2023, com erro-padrão bootstrap de 0,0039, contra 0,7644 no teste de 2024: a diferença é da ordem de dois erros-padrão, e não na direção de piorar. Por ano de início a série vai de 0,7890 em 2020 a 0,7680 em 2024, com o fundo em 2022, dentro do treino.⁵ O que a deriva estraga é o nível, não a ordem, e é por isso que uma recalibração conserta o primeiro sem custar nada do segundo.

As quatro impossibilidades

Quatro regras proíbem combinações de valores nesta base, e são as quatro cercas: uma vem do formulário, uma do calendário da campanha, e duas da definição de coorte que este curso escolheu. De cada uma se mede a mesma coisa: a fração da amostra que está **em cima** da fronteira, aquela para quem uma única perturbação já cai do lado impossível.

O portão do funil. As treze comorbidades só aparecem preenchidas nos registros em que o campo de fator de risco diz que há algum; onde ele está em branco, o bloco inteiro está em branco junto. A ficha oferece um “não” explícito, mas ele nunca foi usado: em seis anos de base, o valor “não” não aparece uma única vez. O vazio, portanto, não diz que o paciente não tem



a barreira: a função que escolhe o modelo levanta uma exceção se enxergar o teste

Figura 1. O protocolo que escolheu o modelo do curso: os candidatos aprendem no treino, a escolha acontece na validação, e o teste é lido uma vez, depois dela. A barreira do meio é código, não promessa: a função que escolhe o modelo levanta uma exceção se enxergar o teste. A figura ensina o desenho do estudo; o placar com todos os candidatos vive no módulo 00.

⁴Módulo 00: o risco médio que o modelo prevê no teste de 2024, ao lado da letalidade que de fato se observou nesse ano.

⁵Módulo 00, internals do modelo §2: a AUC por ano de início. O erro-padrão vem do bootstrap pareado do estudo de seleção, em SELECTION.md.

comorbidade; diz que a pergunta não foi respondida. Marcar uma comorbidade nesse estado contradiz um portão que, medido nos seis anos da base, nunca foi contrariado.

A pré-campanha. A campanha de vacinação tem data de início, e quem adoeceu antes dela quase certamente não tinha dose alguma. As exceções existem e a base as registra sem corrigir, porque houve voluntários de ensaio clínico e brasileiros vacinados no exterior. A cerca trata a regra como quase-certeza, não como lei: a linha que ela barra é a de quem adoeceu antes da campanha e tem contagem de doses positiva, e aumentar essa contagem atravessa a fronteira.

O critério-2 por um fio. A coorte deste curso reproduz o filtro do script do Ministério: entra quem foi hospitalizado e marcou tosse ou dor de garganta, e ao menos um entre falta de ar, queda de saturação e desconforto respiratório. Quem entrou marcando **um só** dos dois sintomas do primeiro grupo está por um fio: desligar esse sintoma o tira do filtro, e sem o filtro ele não estaria nesta coorte. É o estado mais comum da amostra, de longe. A ressalva importa: a definição clínica de SRAG em vigor durante toda a janela é mais larga, porque basta síndrome gripal, dois de oito sintomas com a febre entre eles, mais um sinal de gravidade, que inclui a pressão persistente no tórax e a cianose. A cerca é da coorte que construímos, não da definição de caso do país.

O critério-3 por um fio. O mesmo, no segundo grupo, com três sintomas em vez de dois e bem menos gente pendurada nele.

Perturbar uma linha através de qualquer dessas fronteiras fabrica um paciente que não pode existir. Os cinco módulos fazem essa conta pela **mesma** função que conta o impossível (`gate_impossible`), o que torna os números idênticos por construção. Quem é esse paciente, e por que uma regra o escolheu, é a próxima seção.

3. O paciente e as três cercas

Quem é o paciente

O paciente deste relatório não foi escolhido a dedo. Ele veio de uma regra escrita antes de olhar: entre todos os pacientes do ano de teste, aquele cuja predição cai mais perto da fronteira da decisão, que este relatório fixa em meia probabilidade por convenção de exposição e não por ser um ponto de operação clínico, com o identificador servindo de desempate.

O escolhido, pela regra do módulo 00, é um homem de 90 anos, do Sudeste, que adoeceu na semana 34 de 2024, com uma dose de vacina antes do sintoma e cardiopatia declarada. Ele é o **paciente-regra**, e as cinco perguntas deste relatório são feitas sobre ele.

Estar em cima da fronteira não é acaso conveniente: é a condição que torna as cinco respostas comparáveis. É ali que a reta local do LIME não degenera numa constante e que as forças do SHAP se cancelam de forma

legível. Um paciente confortavelmente de um lado só esconderia o que cada método faz quando é obrigado a decidir.

Dois outros aparecem, cada um com uma razão declarada. Os módulos 01 e 03 usam um segundo, escolhido pela mesma regra mas restrito a quem está exposto às três cercas, chamado aqui de **vulnerável**: ele existe para mostrar que a quantidade de ficção que um método fabrica depende de **quem** está sendo explicado. O módulo 04 precisa de um terceiro, com predição bem mais alta, porque contrafactual pede alguém com o que perder.

Nas figuras de ponto deste relatório, **a forma diz de onde o ponto veio; a cor diz o que ele é**. Círculo é paciente real, colorido pelo desfecho **observado**: azul sobreviveu, terracota morreu. Quadrado é vizinho **sin-tético**, colorido pela **predição do modelo**. O X escuro é o paciente sendo explicado. No tracejado, escuro e longo é a fronteira do modelo, cinza e médio a vizinhança que um método construiu, claro e curto só andaime de eixo.

A cor carrega mais um eixo em duas das figuras, e vale dizer qual antes que elas apareçam. Em barras que varrem uma grade de valores, verde é o ponto que podia existir e terracota o que a cerca barra: ali a cor é **possibilidade**, não desfecho. E quando dois modelos dividem o mesmo painel, a cor separa os instrumentos, azul para o comitê de árvores e âmbar para a logística. Três eixos, portanto, e cada figura diz na legenda com qual deles está pintando.

A ficha do SIVEP não é um formulário plano: ela **des-liga campos**. Onde o campo de fator de risco está em branco, as treze comorbidades abaixo dele estão em branco junto. O vazio que sobra ali não é dado faltante. É informação: diz que a pergunta não foi feita.

Por isso o tratamento separa três leituras do vazio: **não se aplica** (o portão desligou o campo), **ausente** (o campo estava aberto e ficou em branco) e **ignorado** (alguém registrou que não sabe). Fundir as três transforma resposta em buraco: o dado faltante cresce sem que nada tenha se perdido, e quem imputa por cima inventa comorbidade num paciente a quem a pergunta nunca foi feita.⁶

Como as features são **conjuntamente restritas**, todo método que perturba uma feature de cada vez fabrica pacientes que não podem existir. As quatro regras da seção anterior viram três cercas nos módulos, porque o critério-2 e o critério-3 são a mesma cerca lida em dois grupos de sintomas: a definição da coorte.

cerca	o que ela proíbe
portão do funil	marcar comorbidade onde o campo de fator de risco ficou em branco
calendário da campanha	dar uma dose a quem adoeceu antes de a campanha começar
definição da coorte	apagar o único sintoma que fez o paciente entrar na coorte

Fonte: módulo 00, `MODEL.md`; a mesma função nos módulos 01 a 05

⁶Módulo 00: fundir os três estados infla o dado faltante por $1,8\times$ a $5,7\times$ conforme o ano.




Figura 2. A variável-funil: o campo de fator de risco governa se as comorbidades abaixo dele chegam a ser perguntadas. A figura diz quais respostas são possíveis, não quantos pacientes caem em cada ramo.

E a cerca não é vista pela geometria. A distância de Gower compara duas fichas célula a célula, pondo números e categorias na mesma escala; por ela o ponto impossível fica mais perto de um paciente real do que o paciente real mediano fica do vizinho dele. Trocar um nível de categoria custa o mesmo, seja a troca possível ou impossível: nenhum limiar sobre essa distância pega a contradição.

4. Ceteris paribus: e se a idade fosse outra?

Congela-se o paciente, escolhe-se uma variável e uma **grade** (a lista de valores que ela vai assumir) e plota-se a predição em cada valor. Sem modelo intermediário, sem sorteio, sem aproximação: a curva **é** a saída do modelo (Molnar, 2025), e é por não aproximar nada que o método mais simples do curso expõe o problema que todos os seguintes herdam.

Um modelo de árvores não lê a idade como um valor que escorre: ele pergunta se a idade passou de um corte, depois se passou do seguinte. Entre dois cortes ele não muda de opinião, então a predição fica parada e pula de uma vez. A curva vira uma **escadaria**.

E a escadaria se lê errado com facilidade. Numa grade grossa, a altura de um degrau é propriedade da

grade: cada salto visível soma vários saltos verdadeiros, e pedir a predição em idades mais próximas parte o degrau grande em degraus menores. Mas o refino tem fim. A partir de certo passo os degraus param de encolher, e a altura que sobra é do modelo.⁷ A amplitude, do ponto mais alto ao mais baixo, não se move em refino nenhum. Leia posições de corte primeiro, e só leia altura de degrau depois que refinar a grade tiver parado de mudá-la.

A logística não tem interações, e o efeito disso é a forma: ela desenha a mesma curva em S para **todo** paciente. O resto da ficha entra somando, e uma soma feita antes de a conta virar probabilidade desliza a curva ao longo do eixo em vez de levantá-la. Dois pacientes diferem em **onde** ela sobe, não em como sobe, e no trecho que o gráfico mostra isso muda a altura e a inclinação ao mesmo tempo. O modelo do curso desenha uma curva com forma própria por paciente, e é daí que sai o ganho que nenhum coeficiente global exhibe. Nas doses os dois discordam de ponta a ponta⁸, e aí mora uma armadilha: dizer que o modelo do curso “desce nas doses” é ler a ponta do gráfico, não o paciente, porque perto do próprio paciente a inclinação é **positiva**.




Figura 3. O mesmo paciente em dois modelos, na idade e nas doses: a escadaria do modelo do curso contra a rampa da logística, com a cor separando os instrumentos e não os desfechos. Atenção à direção do painel direito: as duas curvas sobem com as doses, e nenhuma das duas mede efeito de vacina. Na campanha brasileira as doses foram primeiro para os idosos, os imunocomprometidos e os portadores de comorbidade, e as adicionais só para eles, de modo que a contagem de doses é, nesta ficha, um marcador de fragilidade. O perfil prevê, não intervém.

⁷Módulo 01: em quatro refinamentos da grade de idade a amplitude fica em 0,4809 e o maior salto cai de 0,1387 para 0,0852, e aí não cede mais.

⁸Módulo 01, walkthrough §1b: a fig. 12.5 do livro, refeita. Nas doses a logística sobe 0,217 e o modelo do curso termina 0,044 abaixo.

A resposta, e o preço. Para a pergunta do título o método responde direto, lendo a curva de idade no valor que interessa. E responde barato: sem sorteio no caminho, repetir a conta devolve a mesma curva. O preço é que a resposta vale para uma linha fabricada, e quanto dela é ficção depende de quem se explica: para o paciente-regra nenhuma das oito variáveis de maior peso fabrica um impossível; para o vulnerável, que está em cima das três cercas ao mesmo tempo, as três variedades que o caderno tenta caem fora ponto a ponto. A concentração da ficção é propriedade da coorte, não do método.

5. ICE: os outros respondem igual?

O ICE desenha um perfil *ceteris paribus* por paciente, todos no mesmo eixo (Goldstein et al., 2015). Esse conjunto de curvas é o **feixe**, e o que ele acrescenta é heterogeneidade: o modelo trata todos do mesmo jeito? A leitura do capítulo é de olho nu: se as curvas seguem o mesmo curso, não há interação **óbvia** naquela variável, e a média delas, o **PDP**, resume bem. A inversa não vale, e Goldstein et al. propõem por isso um teste formal: um feixe que parece paralelo num sorteio de duzentas curvas não prova ausência de interação. Aqui isso não pesa, porque a leitura de olho nu **falha**, e é a falha que serve de evidência.

Uma curva por paciente significa que, com a base inteira, o gráfico vira uma mancha preta: é o amontoamento (**overcrowding**) de que o capítulo avisa. Por isso se sorteia um subconjunto, e a regra do sorteio se declara.⁹ A **semente** é o número que fixa o sorteio: quem rodar o caderno de novo obtém as mesmas curvas, e

é isso que torna a figura reproduzível. **Estratificar por ano** é tirar a mesma quantidade de pacientes de cada ano; sem estrato, 2020–2022 dominaria a amostra e o regime sumiria no desbalanceio.

Está aí a lição do PDP: a média fica entre duas populações e não descreve nenhuma.¹⁰ **Centrar** as curvas confirma: subtraído de cada uma o valor que ela tem no início da grade, todas partem do zero e sobra só a forma, quase paralela, com os pacientes subindo do mesmo jeito de níveis muito diferentes. O PDP acerta a forma e erra o nível de todos ao mesmo tempo, o modo de mentir mais educado que existe.

A **derivada** é a inclinação da curva, e numa escadaria ela não existe em cada ponto: o que o caderno desenha é a diferença entre dois pontos vizinhos da grade, que aqui distam dois anos, dividida por esse intervalo. Lida assim, ela diz quanto a predição muda por um ano a mais, na grade usada. Ela acha o efeito onde ninguém procurava, num pico pediátrico. Não é biologia: é o modelo lendo uma coorte em que a SRAG pediátrica pré-COVID era bronquiolite.

A resposta, e o preço. Não, os outros não respondem igual, e a diferença é o ano em que adoeceram. O preço é que a ficção se multiplica por duzentas curvas e continua contável: o feixe de idade não tem um ponto impossível, o de doses fabrica 18% e o de tosse, 54%.¹¹ A variável varrida decide se o feixe é retrato ou fábula.

6. LIME: por que esta predição, localmente?

O LIME (Ribeiro et al., 2016) não abre o modelo. Ele fabrica vizinhos artificiais em volta do paciente, pergunta ao modelo o que ele prevê em cada um, dá mais peso




Figura 4. Olhe a rampa de intensidade: quanto mais escura a curva, mais letal o regime em que o paciente adoeceu, e as de 2020 correm por cima das de 2024, então o teste do capítulo falha de propósito. A figura não mostra efeito da idade: cada ponto é a predição numa linha fabricada.

⁹Módulo 02: o feixe sorteia 200 pacientes, 40 por ano, com semente 42.

¹⁰Módulo 02, walkthrough §1: aos 80 anos o feixe vale 0,481 em 2020 e 0,303 em 2024, e a média do feixe, que é o PDP desta amostra estratificada e não o da coorte, reporta 0,400.

¹¹Módulo 02: 252 dos 1.400 pontos do feixe de doses caem antes de a campanha começar, uma fração derivável antes mesmo de medida.




Figura 5. Os seis passos do método sobre um corte ceteris paribus do modelo do curso: fronteira, vizinhança, perturbação, previsões, pesos e reta. Só o painel D consulta o modelo. A figura não mostra uma vizinhança de pacientes: cada coluna da nuvem é sorteada sozinha.

aos mais parecidos e ajusta uma reta simples nesse conjunto. Essa reta é o **substituto**: imita o modelo complicado só ali perto, e seus coeficientes são a explicação. O **kernel** decide o peso de cada vizinho conforme a distância, e a largura dele define o tamanho de "ali perto".

O substituto nunca passa por cima do modelo. A predição continua vindo do XGBoost; a reta só a resume.

Três surpresas estão na figura. A nuvem não está centrada no paciente: o gerador, com as contínuas não discretizadas e o sorteio no seu padrão, a centra na média do treino, e o paciente fica a vários desvios do centro da própria "vizinhança". O kernel descarta quase tudo, e sobram poucos vizinhos com peso apreciável. E é nesse deserto que a reta é ajustada.

A vizinhança tem dois defeitos, e só um tem conserto fácil. Declarar quais colunas são discretas conserta a **gramática**: a nuvem para de produzir códigos que não existem na ficha e doses negativas, e nada avisava, porque a função que entrega os vizinhos ao modelo arredonda em silêncio. Não conserta a **biologia**: cada coluna contínua sorteada sozinha, a correlação entre calendário e doses some, e os vizinhos impossíveis continuam lá, quase um terço dos do paciente-regra e quatro em cada cinco dos do vulnerável.¹²

A resposta, e o preço. O LIME dá um ranking com sinal, e o topo dele é firme entre sementes: no módulo 03, dez delas dão o mesmo top-5, sem troca de sinal no top-8. O preço é o R^2 : ele mede o quanto a reta reproduz a nuvem ponderada, que é a **fidelidade local** no sentido

de Ribeiro, e não a fidelidade **ao paciente**, o quanto a explicação acerta neste caso. Por ser normalizado pela variância da nuvem, o R^2 pode ir a zero justamente onde o erro no paciente é zero: com kernel estreito o substituto degenera na constante certa e entrega R^2 zero com erro zero, a explicação vazia perfeita; na largura padrão da biblioteca, R^2 e erro sobem juntos.¹³ Nenhuma largura compra as duas, e o capítulo é franco: definir a vizinhança certa é problema em aberto (Molnar, 2025). A regra que sobra é dura: não ranquee explicações por R^2 . A amostragem fora da variedade abre ainda um ataque (Slack et al., 2020): os vizinhos sorteados não se parecem com pacientes reais, então dá para treinar um detector que os reconheça. Um modelo montado com esse detector responde aos vizinhos com uma cara inocente e segue enviesado nos pacientes de verdade, e o LIME explica a cara, não o modelo.

7. Contrafactuais: o que teria de mudar?

Os três métodos anteriores perguntam "o que pesou?". O contrafactual inverte: qual é a menor mudança que muda a saída? Com isso, as cercas deixam de ser diagnóstico de método doente e viram **restrição de busca**.

A ideia vem de Wachter et al. (2018): a menor mudança na ficha que leva o modelo à saída desejada, sem abrir a caixa. A perda que eles escrevem pesa duas coisas, chegar à saída e ficar perto do original. Como a saída é um paciente hipotético, o campo foi somando exigências depois, e o capítulo de Molnar as reúne (Molnar, 2025): **validade**, a mudança cruza mesmo o

¹²Módulo 03, walkthrough §4: a contagem de impossíveis reprova 30,6% dos vizinhos sorteados em torno do paciente-regra e 79,2% dos do vulnerável.

¹³Módulo 03, walkthrough §5: o kernel estreito mede R^2 0,00 com erro 0,00, e o da largura padrão, R^2 0,68 com erro 0,028.




Figura 6. Cada barra é uma banda de risco, e a altura é a fração de pacientes dessa banda para quem algum movimento ao alcance de uma pessoa cruza o limiar: olhe o gradiente, que desce conforme o risco sobe. Barra nenhuma não é paciente condenado, nem a figura mede eficácia: é o método sem o que prescrever.

limiar; **proximidade**, o hipotético fica perto do real; **es-parsidade**, mudam poucas coisas; **plausibilidade**, ele poderia existir; **diversidade**, há mais de um caminho.

O módulo não usa biblioteca, e a razão é uma boa lição de engenharia: o espaço de mudanças declarado cabe inteiro na memória, então o caderno enumera todas em vez de otimizar a perda de Wachter. Isso compra cobertura completa, determinismo sem semente e custo de milissegundos. O paciente aqui não é o paciente-regra: o módulo 04 pede alguém com o que perder, e caiu num paciente de 32 anos, com quatro doses, síndrome de Down, doença neurológica, imuno-depressão, doença renal e outras morbidades. Foram Down e imunodepressão que o puseram entre os grupos prioritários da campanha, e daí as quatro doses.

O gradiente é a leitura difícil da figura: a fração com saída cai banda a banda conforme o risco sobe, e some na última, onde há dezenove pacientes só, poucos demais para separar “nenhuma saída” de “poucas”.¹⁴ A direção é clara; a ponta é frágil. E a busca livre explica por quê: a melhor mudança única que ela encontra é a saturação baixa passar a “não”, isto é, supor um paciente que nunca ficou hipoxêmico, e isso é **consequên-cia** da doença, não alavanca; atrás dela vêm voltar a ter 10 anos e recuar o calendário para os primeiros meses da pandemia.

Três histórias sem um ingrediente em comum levam o paciente para o lado certo do limiar, e param em previsões bem diferentes: o efeito Rashomon impresso, explicações diferentes e igualmente válidas para o mesmo caso. Qual delas se contaria ao paciente?

A resposta, e o preço. A resposta honesta é **não neste modelo**: os dois candidatos ao alcance deste paciente não movem a previsão, e não poderiam mover muito, porque a única família que o estudo declara aci-onável é a contagem de doses, uma exposição do pas-sado, indisponível a quem já está internado. O espaço de variáveis não contém um único tratamento: a venti-

lação e a UTI saíram como vazamento, e os campos de antiviral da ficha nunca entraram. Um modelo sem ala-vanca não tem contrafactual acionável por construção, e é isso que a figura mede, não o prognóstico deste paciente, para quem oxigênio, antiviral precoce e leito continuam existindo fora do modelo. Um método que só sabe prescrever precisa saber dizer de onde vem o seu silêncio.

O preço tem duas partes. Válido não é alcançável: os melhores candidatos passam na cerca, mas pedem uma máquina do tempo, e é bom lembrar que a máquina do tempo levaria a um lugar pior: em 2020, sem vacina e com hospitais saturados, um jovem imunodeprimido morria mais, não menos. E a plausibilidade se decide sobre o candidato inteiro, não sobre o movimento: re-cuar o calendário sozinho cai na cerca da campanha, recuá-lo com zero doses não cai.

8. SHAP: quanto cada feature pesou?

O SHAP (Lundberg & Lee, 2017) responde repartindo, e a regra de partilha vem de um teorema que Lloyd Shapley provou em 1953, sobre como repartir o ganho de um jogo cooperativo. A previsão deste paciente é o resultado da partida; o ganho é a diferença entre ela e a previsão média, a de quem nada sabe sobre ele; os jogadores são os valores das variáveis. O valor de Shapley reparte esse ganho entre eles de forma que a soma feche. Em árvores, o TreeSHAP (Lundberg et al., 2020) faz a conta em tempo polinomial e sem sorteio, e o modelo do curso já a traz pronta (pred_contribs), que é a variante **path-dependent**: exata para a função-valor que ela adota, a que preenche as ausências seguindo as frequências dos próprios caminhos da árvore. Todos os ϕ desta seção vêm dela. Aqui cai a única exceção do relatório. O valor de Shapley é agnóstico de modelo, e existe uma versão dele que trata qualquer modelo como caixa fechada, o KernelSHAP (Lundberg & Lee, 2017). O TreeSHAP não é: ele percorre as árvores. Troca-se a

¹⁴Módulo 04, walkthrough §5: dos 624 pacientes de alto risco, 30,3% têm contrafactual acionável, e a fração cai conforme o risco sobe.




Figura 7. Um cabo de guerra que empata: a idade empurra para cima, a vacinação declarada e o calendário freiam, e o que se olha é a soma, que cai exatamente sobre a margem deste paciente. A figura não é um contrafactual: reparte o que já aconteceu.

generalidade pela conta exata e barata, e a troca fica dita em vez de escondida.

Antes da figura, a escala. As contribuições vivem na **margem**: o número que o modelo soma por dentro e que só depois vira probabilidade. É aí que somar as contribuições das 800 árvores do módulo 00 faz sentido, porque o modelo é aditivo **na margem**, e só nela. A ligação que transforma margem em probabilidade é uma curva, e a curva de uma soma não é a soma das curvas: somar probabilidades não fecharia em ponto nenhum do eixo, não só nas pontas.

Que a soma feche é o que separa o SHAP dos outros quatro métodos: aqui não há ajuste que possa sair bom ou ruim, como o R^2 do LIME. As parcelas fecham porque um axioma manda, a eficiência, e a garantia vira verificação, conferida linha a linha no teste inteiro.¹⁵

O que a figura **não** significa é causa. Um ϕ positivo não diz que aumentar aquela variável aumentaria a predição, e também não é o que sobra quando se apaga a variável do modelo. Ele é uma média: monte o paciente variável por variável, em todas as ordens possíveis, e anote quanto a predição se move no instante em que **esta** entra. O ϕ é a média dessas anotações, contada a partir da predição de quem nada sabe sobre o paciente. Não é o efeito daquele valor com o resto da ficha parado. E o modelo dá o caso que quebra: o ϕ das doses de vacina é **positivo** nos vacinados. Isso não é efeito de vacina, e são três razões somadas. A primeira é a repartição entre duas colunas quase colineares: o crédito protetor vai para a que declara a vacinação, e sobra para a contagem de doses o papel de marcar **quem** se vacinou. A segunda é justamente quem: a campanha priorizou idosos, imunocomprometidos e portadores de comorbidade, e as doses adicionais foram só deles,

de modo que a contagem de doses é, nesta ficha, um marcador de fragilidade que os treze checkboxes não medem. A terceira é o que falta: o modelo não vê o tempo desde a última dose, então uma dose tomada há três anos e uma tomada no mês passado são o mesmo valor. Nada disso mede o que a vacina fez; mede o que a triagem fez. O antídoto está no módulo anterior: subir as doses deste paciente quase não move a predição.

Duas medições fecham o arco. A primeira liga o SHAP à deriva de regime: a variável de calendário está entre as primeiras para mover as predições de 2024 e cai para o meio da tabela pelo ganho das divisões (gain), a medida de quanto ela ajudou a construir as árvores. Pela atribuição ela é terceira; pelo ganho é a 19ª de 40.¹⁶ Importância para prever não é importância para treinar.

A segunda é o preço do condicionamento. Apagar uma variável para medir o que ela vale tem duas versões: seguir os caminhos que as árvores percorrem de fato, respeitando as correlações aprendidas, ou apagá-la mesmo, montando pacientes que são metade este e metade outro. As direções batem; as magnitudes divergem onde as correlações moram. O caminho das árvores também cobra o seu: ao respeitar as correlações, ele pode dar crédito a uma variável que o modelo nem usa, só porque ela anda junto de uma que usa (Molnar, 2025).

A resposta, e o preço. O SHAP responde a última das cinco perguntas com números que somam, e é a única resposta auditável do relatório. O preço da variante que usamos é o parágrafo acima: crédito que escorre para variáveis correlacionadas. O da alternativa intervencional é outro, e foi contado, pela mesma função que conta o impossível nos outros módulos: os híbridos que a função-valor dela pressupõe são quase um quarto

¹⁵Módulo 05, internals §1: as 40 contribuições mais a base reproduzem a margem com desvio máximo $1,05 \times 10^{-5}$ nas 16.142 linhas do teste.

¹⁶Módulo 05, walkthrough §4: 19ª de 40 pelo ganho do treino, contra a terceira colocação por média $|\phi|$ no teste de 2024.




Figura 8. O painel-armadilha é o da direita: quem não declarou dose recebe crédito negativo; as doses declaradas recebem crédito positivo. Ele não compara vacinado com não vacinado, nem mede efeito de vacina: mostra como o modelo divide crédito entre variáveis que andam juntas.

impossíveis.¹⁷ A limitação que o livro-texto enuncia fica contada, em vez de citada.

9. As cercas, lado a lado, e a deriva

Os cinco módulos contaram a mesma coisa com cinco instrumentos, e sempre pela mesma função, escrita uma vez no módulo 00 e importada pelos cinco cadernos. A tabela compara métodos, não implementações.

método	o que foi contado	fração
módulo 01	pacientes da amostra para quem marcar comorbidade cairia no portão	37,3%
módulo 01	pacientes da amostra que marcaram só um dos dois sintomas do primeiro grupo	79,6%
módulo 02	pontos do feixe de doses, onde a cerca é da variável	18%
módulo 03	vizinhos sorteados em torno do paciente-regra	30,6%
módulo 03	os mesmos vizinhos, em torno do vulnerável	79,2%
módulo 04	candidatos a contrafactual, uma célula por vez	3,5%
módulo 05	linhas híbridas montadas pela variante intervencional	23,1%

Fonte: walkthrough §2 (01), §3 (02), §4 (03), §2 (04) e §7 (05)

A tabela junta, de propósito, duas contas diferentes. As duas primeiras linhas medem **exposição da coorte**: quantos pacientes reais já estão em cima de uma cerca, antes de qualquer método rodar. As outras cinco medem **ficção do método**: quantos dos pontos que o método fabricou não podem existir. A primeira conta é do mundo; a segunda é do instrumento. Os denominadores também não são os mesmos: as duas primeiras linhas se medem sobre a amostra inteira, e as outras cinco sobre o que cada método fabricou, que vai de uma centena de candidatos a alguns milhares de vizinhos. As frações não se comparam entre si, e cada uma se lê contra a sua própria nota de rodapé. E a tabela não é um ranking de qualidade. A taxa de ficção é propriedade conjunta de três coisas: o método, a variável perturbada e **quem** está sendo explicado. O contrafactual fabrica pouco porque parte de um paciente real e move uma célula por vez. O LIME fabrica muito porque sorteia todas as colunas de uma vez, e fabrica mais que o dobro no vulnerável, pelo mesmo gerador, já que a nuvem nem olha para o paciente.

A deriva, vista por cinco instrumentos

Não são cinco achados, é um só, visto de cinco ângulos. Ele nasce na base, e em duas contas que não devem ser somadas. No módulo 00, na SRAG inteira, com todas as etiologias e todas as idades, a letalidade bruta anual cai




Figura 9. O que olhar é a cor das barras, e aqui ela é o eixo da **possibilidade**, não o do desfecho: verde é a dose que podia ter existido, terracota a que a cerca barra. A mesma varredura, na mesma grade restrita, sobrevive inteira no paciente pós-campanha e é barrada quase toda no pré-campanha, onde só a dose zero podia ter existido. A figura não mostra efeito de vacina; mostra em quais pontos a pergunta podia ser feita. É assim que o remédio do capítulo funciona, dizendo **quando não perguntar**.

¹⁷Módulo 05, walkthrough §7: 23,1% das 2.460 linhas híbridas montadas pela variante intervencional são impossíveis.

de 29,0% em 2020 para 8,6% em 2024, mas a maior parte dessa queda é troca de população: no mesmo módulo 00, a fração COVID vai de 59,8% a 11,6%, com a SRAG voltando a ser majoritariamente pediátrica. Dentro da coorte deste relatório, onde essa troca já foi filtrada, a queda que resta é a do treino para o teste, de 31,4% para 18,2%. É essa segunda, e só ela, que o modelo herda como desvio de nível.¹⁸ O ICE dá rosto ao erro, com duas alturas para a mesma idade quando o feixe é estratificado por ano. O SHAP dá um posto: o calendário é das primeiras variáveis por atribuição e fica no meio da tabela pelo ganho na construção das árvores. E o contrafactual mostra o avesso: os melhores candidatos válidos pedem que o paciente volte ao começo da pandemia, que é um lugar onde ele morreria mais, não menos. É a deriva aparecendo pelo lado errado, e um bom lembrete de que válido para o modelo e verdadeiro sobre o mundo são coisas diferentes.

Uma explicação que revela “ano” está, portanto, **correta**. O modelo aprendeu o regime, e escondê-lo seria pior do que mostrá-lo.

10. Limitações, discussão e o que aprendemos

O que os métodos não dizem

Nenhum dos cinco entrega causalidade. Todos leem um modelo treinado em fichas de vigilância, e uma ficha registra **documentação** tanto quanto biologia. O resultado de imagem mostra as duas coisas ao mesmo tempo. Há sinal clínico verdadeiro: entre os laudos informativos, a letalidade cai do típico de COVID para o negativo para pneumonia. E há vazamento, mas ele mora nos níveis não informativos, o ignorado e o campo em branco, que são os mais letais da tabela inteira, enquanto o não realizado não se distingue do típico. Quem morre nas primeiras horas não chega a ter laudo digitado: é gravidade entrando pelo campo vazio, não qualidade de prontuário. Somar as duas colunas às variáveis renderia 0,0038 de AUC, e o preço seria um modelo que credita à existência do laudo o que pertence ao curso da doença.¹⁹

A mesma lógica explica a exclusão mais discutida do Ouro. Admissão em UTI e suporte ventilatório são os dois campos clinicamente mais fortes da ficha, e somá-los subiria bastante a AUC.²⁰ Ficam fora mesmo assim, e o critério não é o tamanho do ganho: é o **instante da predição**. Os dois campos resumem o episódio inteiro, e o suporte ventilatório não tem data nenhuma, enquanto a data de entrada na UTI existe só numa minoria dos registros. Não dá para saber se a ventilação veio antes ou depois do instante em que o modelo seria usado, e é essa impossibilidade que os desqualifica: usá-los é prever a admissão com informação que ainda não existia. Isso infla o desempenho aparente sem tornar o modelo utilizável (Moons et al., 2019; Wolff et al., 2019).

Há ainda o confundimento por capacidade instalada: quem foi ventilado depende de haver leito, e a oferta de leitos era desigual entre as regiões brasileiras. Mover a ventilação num perfil *ceteris paribus* não mostraria efeito de tratamento, mostraria triagem. Aquele número maior não é um modelo melhor da mesma pergunta; é um modelo de outra pergunta.

A lição principal inverte a direção habitual: em vez de usar o método para entender os dados, foram os dados que qualificaram o método. Numa base cuja estrutura de formulário é conhecida, a advertência de Molnar, de que perturbar variáveis de forma independente cria combinações irreais, vira contagem.

A segunda lição veio de um acidente. Quando o estudo de seleção trocou os hiperparâmetros do modelo do curso, os cinco módulos foram re-sincronizados afirmação por afirmação, e deu para ver **que tipo** de frase sobrevive. Caíram quase só leituras de ponta e narrativas bonitas; sobreviveram as contagens de cerca, que não se moveram, porque medem a base e não o modelo. Vale escrever cada frase sabendo de qual das duas se trata. E há uma terceira classe, mais escorregadia que as outras: a frase que descreve uma escolha nossa e se disfarça de fato sobre a ficha ou sobre a doença. Quase toda cerca deste relatório é assim, e por isso cada uma diz de onde vem.

O que torna este relatório verificável não é o texto, é a regra: todo número em prosa é impresso por uma célula versionada, a frase que o carrega nomeia o módulo, e um script reprova o arquivo quando isso é quebrado. É barato de manter e caro de fingir. O limite da regra também vale dito: ela vigia dígitos, e as afirmações mais arriscadas de um texto como este costumam não ter dígito nenhum.

O próximo capítulo trata do problema vizinho. O ALE não faz média sobre a distribuição marginal: ele acumula **diferenças** de predição dentro de janelas que a base de fato ocupa, e é isso que corrige a extrapolação para fora do envelope dos dados, de que o PDP sofre. Não corrige a cerca, porque a diferença continua sendo tomada com o resto da ficha parado. Para restrição lógica o remédio segue sendo o do módulo 01: dizer quando não perguntar. E a pergunta que abre o curso e o fecha continua a mesma: **quem são as linhas que você acabou de dar de comer ao modelo?**

Disponibilidade de código e dados

Os cadernos, as figuras e os documentos de decisão citados nas notas de rodapé deste relatório são públicos, em github.com/wbendinelli/interpretable-ml-lectures. O módulo 00 traz a base, o modelo e o protocolo de seleção; os módulos 01 a 05 trazem um método por diretório, cada um com um caderno de passo a passo e um de internals, e com as saídas versionadas

¹⁸Módulo 00, MODEL.md: no teste, o modelo prevê 0,2154 onde se observa 0,1824. A série anual da base inteira está no README do módulo 00, na tabela dos regimes.

¹⁹Módulo 00, walkthrough do modelo §5: a célula-armadilha, com a letalidade por nível de laudo ao lado do ganho de AUC que a imagem traria.

²⁰Módulo 00, GOLD.md, decisão 3: com os dois campos, a AUC de teste vai de 0,7644 para 0,8514.

junto do código que as imprimiu. Um ponteiro como “módulo 03, walkthrough §4” se lê ali: `modules/03-lime/notebooks/lime_walkthrough.ipynb`, seção §4. Os microdados do SIVEP-Gripe são publicados pelo Ministério da Saúde no OpenDataSUS; o extrato congelado que serve a todo o curso é o de junho de 2025, e o repositório registra a data porque a ficha muda entre versões.

Referências

- Goldstein, A., Kapelner, A., Bleich, J., & Pitkin, E. (2015). Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation. *Journal of Computational and Graphical Statistics*, 24(1).
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/1705.07874>
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, 2. <https://doi.org/10.1038/s42256-019-0138-9>
- Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (3.º ed.). <https://christophm.github.io/interpretable-ml-book/>
- Moons, K. G. M., Wolff, R. F., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A Tool to Assess Risk of Bias and Applicability of Prediction Model Studies: Explanation and Elaboration. *Annals of Internal Medicine*, 170(1), W1–W33.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. <https://arxiv.org/abs/1602.04938>
- Slack, D., Hilgard, S., Jia, E., Singh, S., & Lakkaraju, H. (2020). Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, 180–186. <https://doi.org/10.1145/3375627.3375830>
- Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. *Harvard Journal of Law and Technology*, 31(2). <https://arxiv.org/abs/1711.00399>
- Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A Tool to Assess the Risk of Bias and Applicability of Prediction Model Studies. *Annals of Internal Medicine*, 170(1), 51–58.